Chapitre 1

Introduction aux architectures de données modernes

Master 2 — Architecture de données avancées

Pr. Khalid Kandali

Année universitaire : 2026 - 2027

Master DSBD - S3

Plan détaillé de la séance

1. Données et systèmes d’information modernes
2. Évolution des architectures de données
3. Architectures centralisées vs distribuées
4. OLTP vs OLAP
5. Batch processing vs Stream processing
6. Data as a strategic asset
7. Data-driven vs AI-driven organizations
8. Présentation d’une architecture moderne de données

Étude de cas : Applications → Base de données → Reporting VS Sources → Ingestion → Storage → Processing → Analytics/AI

1 - Question directrice

Question centrale

Pourquoi une organisation qui possède plusieurs sources, formats, volumes et usages ne peut-elle plus se limiter à « application → base de données → reporting » ?



2 - Définition — donnée :

Définition

Une donnée est un fait, une observation, un chiffre, un mot ou une autre information pouvant être collectée et exploitée.



Important

Une donnée n'a de valeur que si elle peut être comprise, contextualisée, accessible et utilisée correctement.

3 - Données structurées, semi-structurées et non structurées

Structurées

Organisation tabulaire.

Ex. :
ID_Client | Nom | Ville | Solde

Caractéristiques :
schéma explicite, colonnes, types, requêtes structurées.

ID_Client	Nom	Ville	Solde
C001	Ahmed	Casablanca	1200
C002	Sara	Rabat	850
C003	Youssef	Tanger	560

Semi-structurées

Structure portée par des métadonnées ou une organisation flexible.

Ex.
JSON, XML, logs.

Le schéma peut varier d'un enregistrement à l'autre.

JSON

```
{
  "id": "C001",
  "nom": "Ahmed",
  "ville": "Casablanca",
  "solde": 1200
}
```

XML

```
<client>
  <id>C001</id>
  <nom>Ahmed</nom>
  <ville>Casablanca</ville>
  <solde>1200</solde>
</client>
```

LOGS

```
2024-03-12
10:15:23
INFO  User
C001 login
from 192.168.1.10
...
```

Non structurées

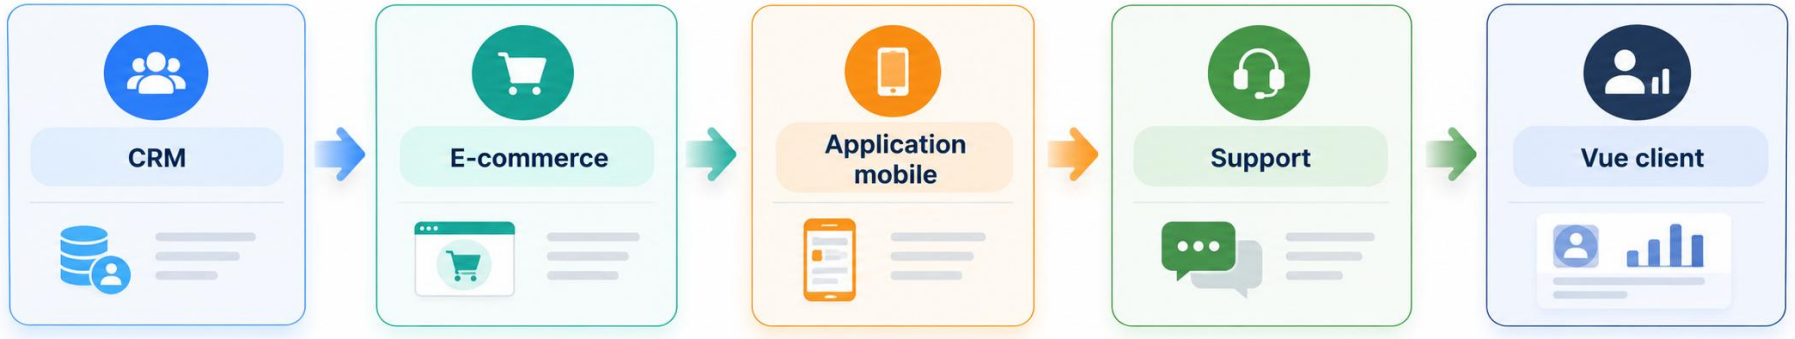
Pas de modèle tabulaire fixe.

Ex. images, vidéo, audio, documents texte.

La difficulté porte aussi sur l'extraction du sens.

Images · Vidéo · Audio · Documents texte

Exemple — même client, plusieurs systèmes



Problème de fragmentation

Le même client peut être représenté différemment : identifiant différent, adresse différente, données manquantes, mises à jour à des moments différents.

Question

Comment intégrer sans perdre contexte, qualité et traçabilité ?

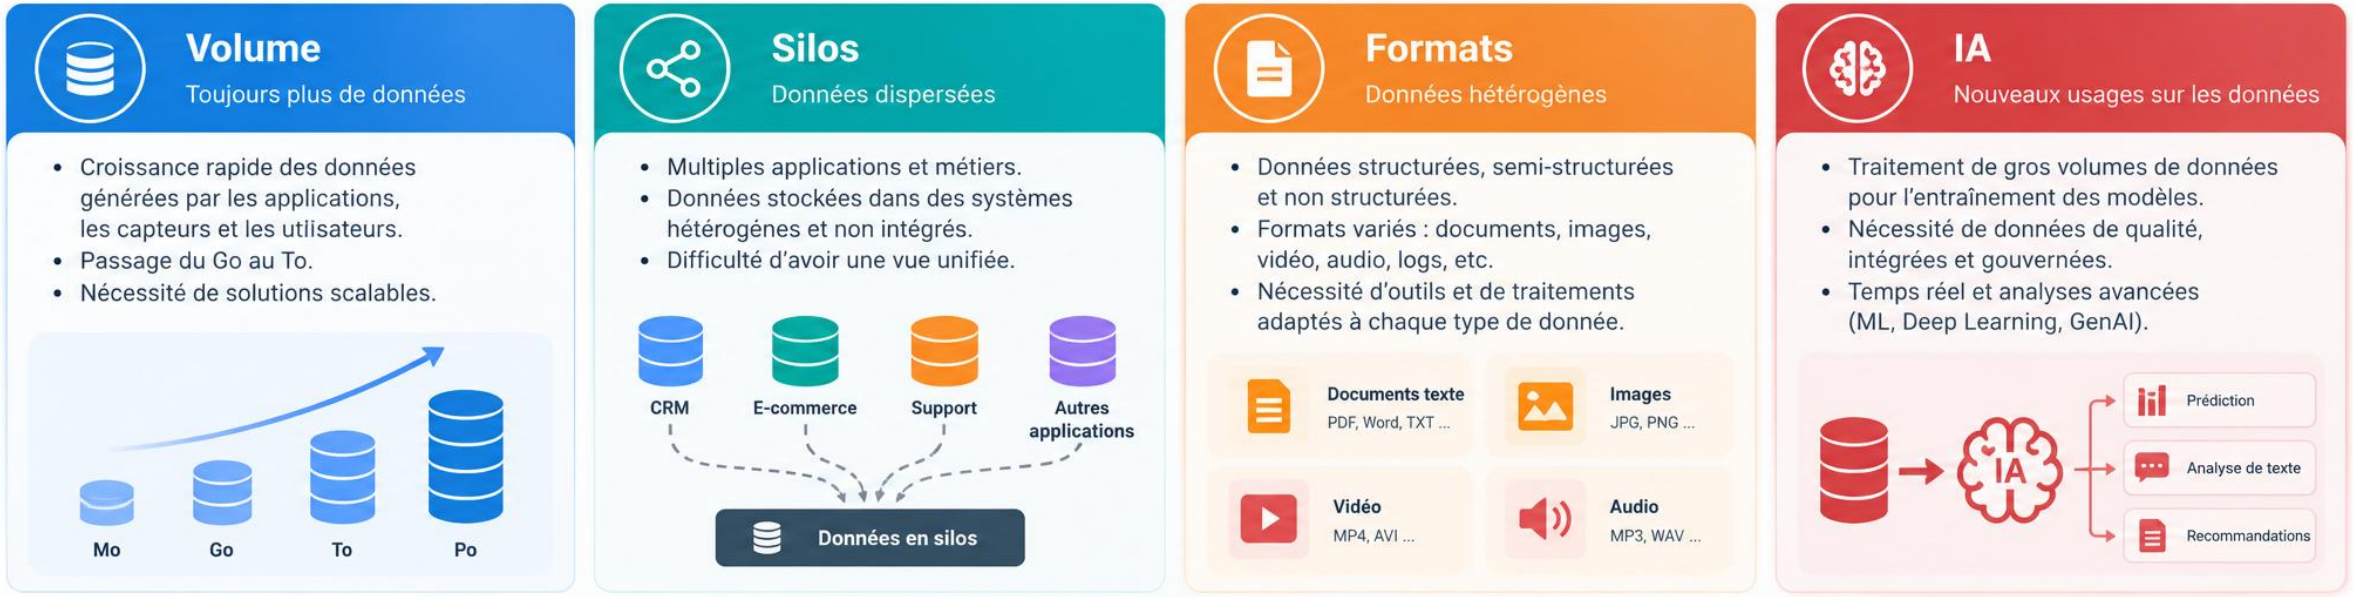
4 - Gestion des données — définition

Définition

La gestion des données est la collecte, le traitement et l'utilisation sécurisés et efficaces des données pour améliorer les résultats de l'entreprise.

- Collecter et intégrer des sources diverses.
- Stocker les données selon les workloads et contraintes.
- Gouverner, sécuriser et contrôler les accès.
- Gérer le cycle de vie, la traçabilité et l'observabilité.
- Fournir des données utilisables aux métiers, analystes, data scientists et ingénieurs IA.

5 - Pourquoi la gestion des données devient-elle complexe ?



Les données doivent être stockées, intégrées, gouvernées, transformées et préparées pour constituer un socle de données adéquat.

6 - Architecture de données — définition opérationnelle

Définition

Une architecture de données décrit comment les données sont gérées, depuis leur collecte et transformation jusqu'à leur distribution et leur consommation.

Pour l'architecte

Elle organise les composants, flux, responsabilités, stockages, traitements, interfaces et contraintes nécessaires aux usages.



Les décisions de l’architecte

Question	Décision
Où arrivent les données ?	Sources / ingestion
Où les conserver ?	Storage
Comment les déplacer ?	Batch / Stream / CDC
Où les transformer ?	Processing
Qui va les consommer ?	BI / ML / AI / applications
Quel niveau de fraîcheur ?	Latence / SLA
Qui peut y accéder ?	Sécurité / gouvernance
Comment vérifier leur état ?	Quality / observability

I. Évolution des architectures de données

1 - Introduction

Chaque génération répond à un problème dominant : transaction, analyse, volume, variété, élasticité, intégration et nouveaux usages.

Évolution des contraintes:

Volume → plus de données
Variété → plus de formats
Vitesse → besoin de données fraîches
Distribution → plusieurs sites / clouds / systèmes
Complexité → plus de workloads
Gouvernance → sécurité, conformité, traçabilité
IA → qualité, représentativité, contexte

Plus les contraintes augmentent, plus l'architecture doit découpler les composants et les responsabilités.

2 - Repères historiques — une lecture par les problèmes

1 Systèmes opérationnels

Problème principal
Gérer efficacement les transactions quotidiennes de l'organisation.

Réponse
Transactions fiables et rapides (OLTP).

Exemple
DB transactionnelle (Oracle, MySQL, SQL Server).



Années 1980 – 1990

2 Data Warehouse

Problème principal
Besoin d'analyse et de reporting sur des données structurées.

Réponse
Analyse structurée et historique.

Exemple
Entrepôt analytique (SAP BW, Teradata, ...).



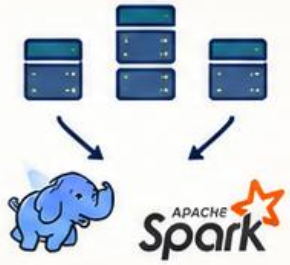
Années 1990 – 2000

3 Big Data

Problème principal
Explosion du volume de données et besoin de traitement distribué.

Réponse
Traitement à grande échelle (clusters).

Exemple
Hadoop, Spark traitement distribué.



Années 2000 – 2010

4 Data Lake

Problème principal
Diversité des formats (structurés, semi-structurés, non structurés).

Réponse
Stockage flexible et à grande échelle.

Exemple
Data Lake (S3, HDFS, ADLS, ...).



Années 2010 – 2015

5 Cloud

Problème principal
Coûts d'infrastructure, élasticité et besoin de services managés.

Réponse
Infrastructure cloud et services de données.

Exemple
AWS, Azure, GCP (Stockage, traitement, AI).



Années 2015 – 2020

6 Lakehouse

Problème principal
Séparer lake et warehouse crée de la complexité et des coûts.

Réponse
Une plateforme unifiée pour l'analytique et l'IA.

Exemple
Databricks Lakehouse, Snowflake, Delta Lake, ...



Années 2020 – 2023

7 Aujourd'hui

Problème principal
Nouveaux usages liés à l'IA (ML, GenAI) et besoin de données de confiance.

Réponse
Intégration, gouvernance, qualité et données prêtes pour l'IA.

Exemple
Plateformes de données modernes (Lakehouse, Data Mesh, Data Fabric).



2023 – ...

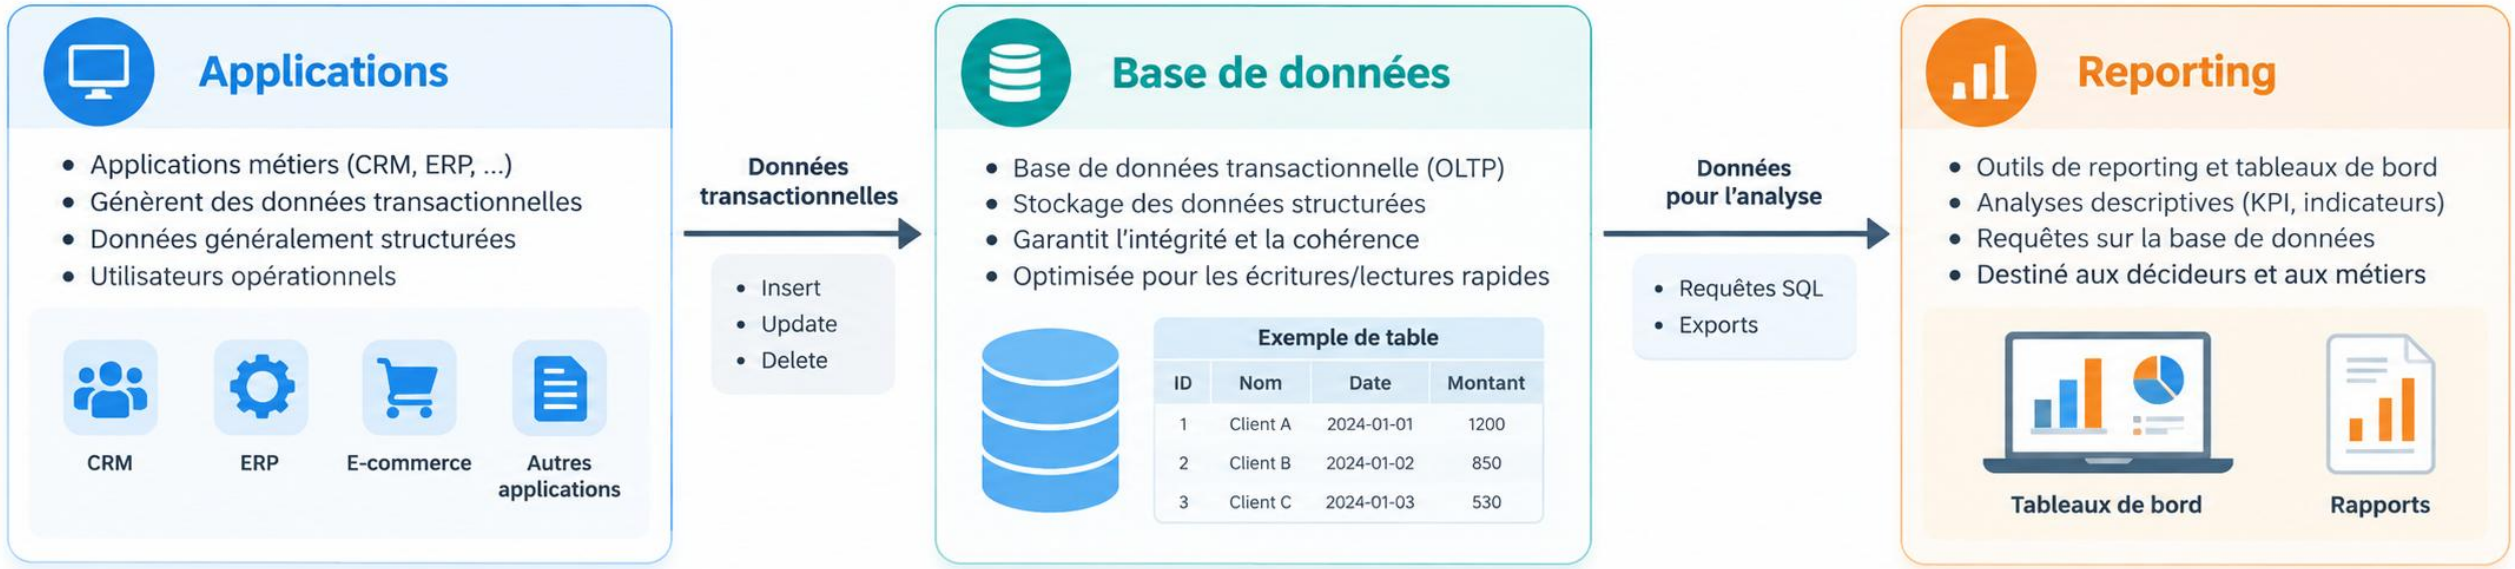
3 - Principe d’évolution architecturale



Idée clé

L’évolution n’est pas « ancienne technologie → nouvelle technologie » ; c’est « nouveau besoin → nouveau compromis architectural ».

4 - Architecture traditionnelle : Applications → Base de données → Reporting



Quand cette architecture fonctionne bien ?

Peu de sources, données principalement structurées, reporting limité, volume maîtrisé et besoins temps réel faibles.

Quand atteint-elle ses limites ?

Quand les workloads et les sources se multiplient.

5 - Data Warehouse — Introduction

Définition

Un Data Warehouse est une plateforme analytique conçue pour stocker des données structurées préparées pour les requêtes, rapports et analyses.

Exemple

Ventes consolidées par jour, produit, magasin et région pour produire des KPI et tableaux de bord.

- Orientation analytique.
- Données généralement transformées avant ou pendant le chargement.
- Optimisé pour requêtes et agrégations.
- Souvent alimenté par des pipelines depuis les systèmes opérationnels.

6 - Data Lake — Introduction

Définition

Un Data Lake permet de stocker à grande échelle des données provenant de sources diverses, souvent dans leur forme brute ou faiblement transformée.

Exemple

Logs, JSON IoT, images, fichiers CSV, données applicatives et documents conservés pour différents usages futurs.

- Grande variété de formats.
- Séparation possible du stockage et du calcul.
- Préservation de données brutes utile pour plusieurs usages.
- Nécessite une gouvernance et des métadonnées pour éviter le « data swamp ».

7 - Lakehouse — Introduction

Idée

Le Lakehouse cherche à rapprocher la flexibilité et l'échelle d'un Data Lake des capacités de gestion et d'analyse attendues d'un Data Warehouse.

Pourquoi ?

Réduire la multiplication des copies et rapprocher BI, analytics et ML sur un socle de données commun.

II. Architectures centralisées vs distribuées

Le choix porte sur l’emplacement des données et du calcul, mais aussi sur la coordination et la gouvernance.

1 - Architecture centralisée — définition

Définition

Les données et/ou le traitement sont principalement regroupés dans une plateforme centrale.

Exemple

Une entreprise concentre ses données analytiques dans un entrepôt unique alimenté par plusieurs applications.

Atouts

Contrôle • cohérence • administration centralisée

Limites

Concentration • scalabilité potentiellement limitée

Question

Le centre devient-il un goulot d’étranglement ?

2 - Architecture distribuée — définition

Définition

Le stockage et/ou le calcul est réparti sur plusieurs nœuds, sites, systèmes ou domaines.

Exemple

Un cluster répartit un traitement massif sur plusieurs machines au lieu d'exécuter toute la charge sur un seul serveur.

Atouts

Scale-out • parallélisme • résilience potentielle

Coûts

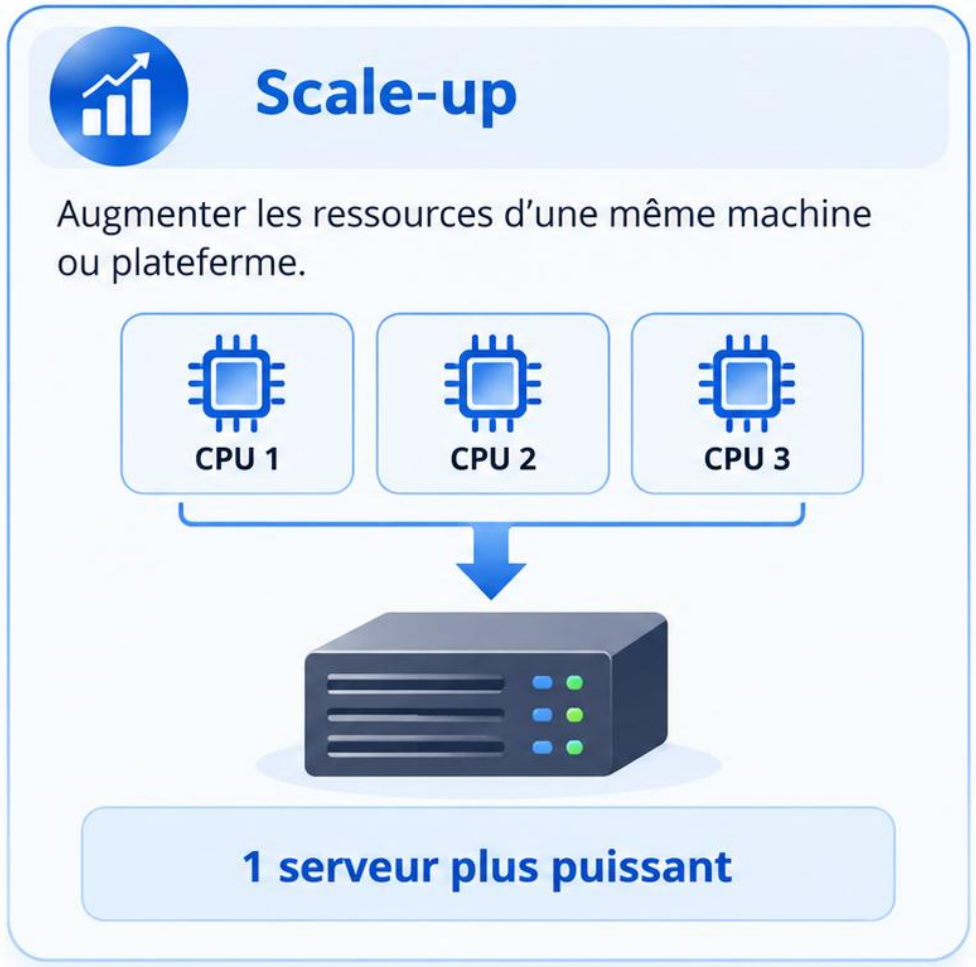
Réseau • coordination • partitionnement • cohérence

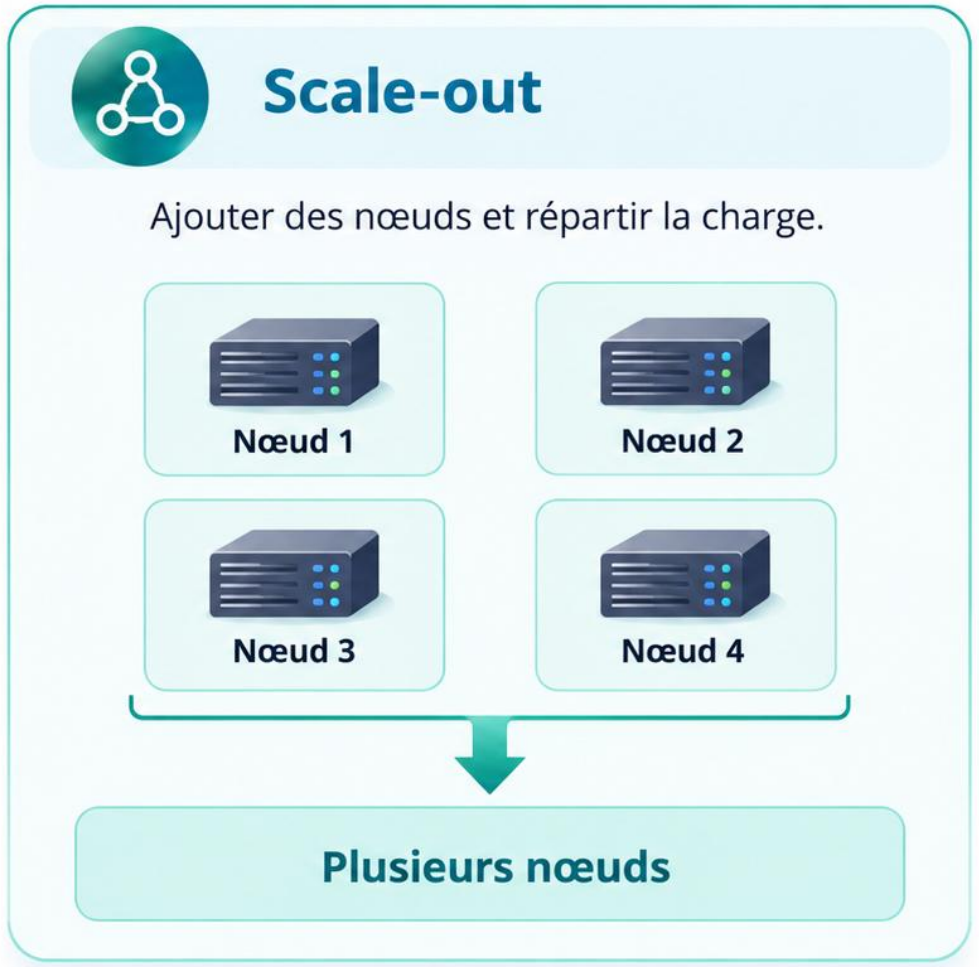
Question

Comment répartir sans perdre contrôle et qualité ?

Centralisé et ***distribué*** ne sont pas deux architectures totalement exclusives. Une architecture moderne peut combiner les deux.

3 - Scale-up vs Scale-out





III. OLTP vs OLAP

Deux familles de workloads : faire fonctionner le métier et analyser le métier.

1 - OLTP — définition et exemple

Définition

OLTP **(Online Transaction Processing)** désigne les traitements transactionnels qui enregistrent et mettent à jour les opérations courantes.

- Nombreuses petites opérations.
- Faible latence attendue.
- Transactions cohérentes.
- Données courantes et opérationnelles.



Exemple :

- Systèmes bancaires.
- Gestion des commandes.
- ERP.

2 - OLAP — définition et exemple

Définition

OLAP **(Online Analytical Processing)** désigne les traitements destinés à explorer, agréger et analyser de grands volumes de données.

Exemple e-commerce

Calculer le chiffre d'affaires par mois, région, catégorie et canal sur cinq années.

- Requêtes complexes.
- Agrégations et scans de grands volumes.
- Historique important.
- Décision et pilotage.

Exemples:

- BI
- Prévisions
- Rapports de performance

3 - OLTP vs OLAP — tableau de comparaison

Critère	OLTP Traitement des transactions	OLAP Analyse des données
Objectif	Opérer	Analyser
Opération	INSERT / UPDATE / transaction	SELECT / agrégation
Données	courantes	historiques
Charge	nombreuses petites requêtes	moins de requêtes mais lourdes
Exemple	commande	KPI mensuel

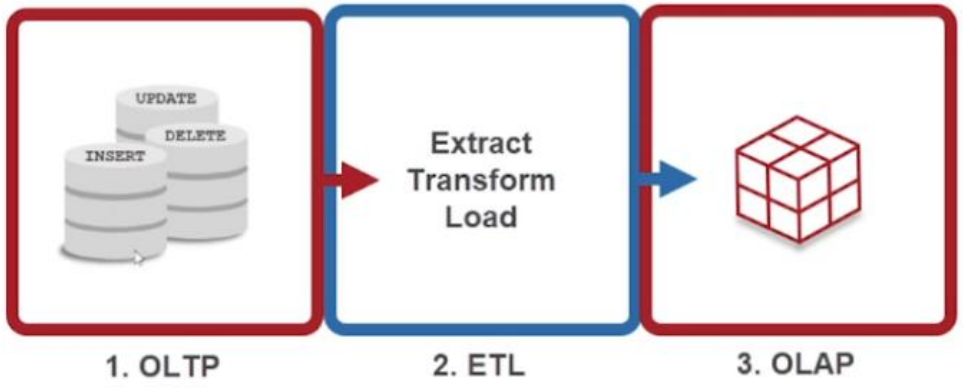
4 - OLTP et OLAP : Complémentarité

OLTP et OLAP sont souvent utilisés ensemble dans les systèmes d'information d'entreprise.

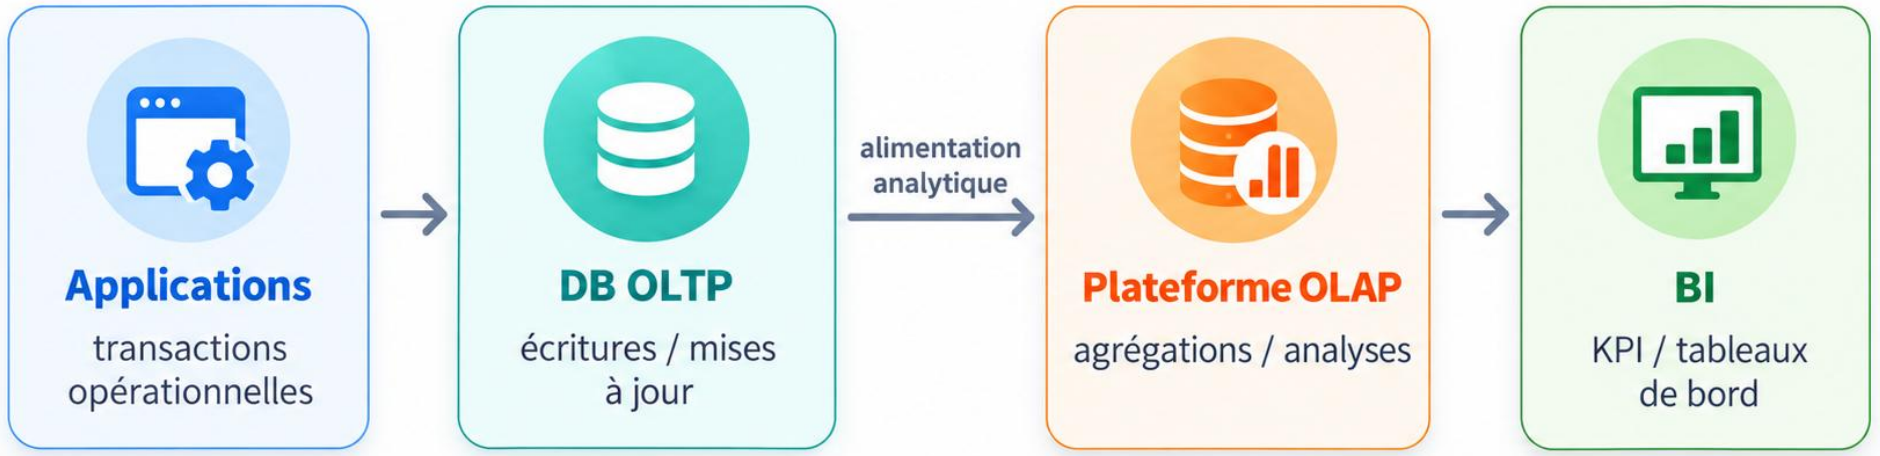
1. OLTP collecte les données : Gère les transactions quotidiennes comme les ventes ou les interactions clients.

2. OLAP analyse les données : Transforme les données OLTP en informations stratégiques via des tableaux de bord et des rapports.

3. Processus ETL : Extraction, Transformation et Chargement des données d'OLTP vers des entrepôts de données pour OLAP.



5 - Pourquoi séparer OLTP et OLAP ?



Un workload analytique lourd peut consommer CPU, mémoire, I/O et réseau. La séparation logique ou physique permet de protéger les workloads transactionnels.

IV. Batch processing vs Stream processing

Le critère principal n’est pas « moderne vs ancien », mais la latence acceptable pour le cas d’usage.

1 - Batch processing — définition

Définition

Le traitement batch regroupe des données sur une période puis exécute un traitement sur un lot.

Exemples

Calcul quotidien des ventes • génération de factures • consolidation nocturne • entraînement planifié d'un modèle.



2 - Stream processing — définition

Définition

Le traitement streaming traite les événements au fur et à mesure de leur arrivée ou sur de très petites fenêtres.

Exemples

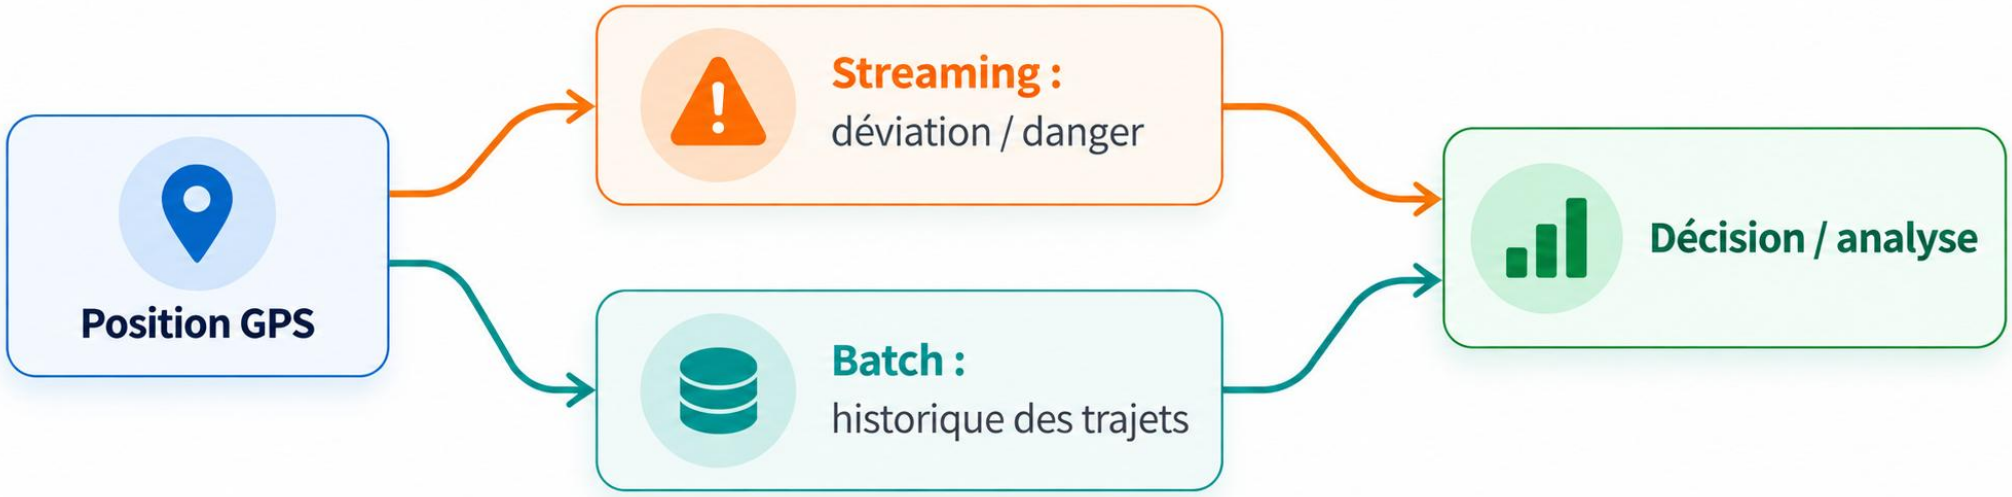
Alerte capteur • détection de fraude • suivi de flotte • monitoring applicatif.



3 - Batch vs Streaming — comment choisir ?

	Batch	Streaming
Latence	minutes / heures / jours	secondes / millisecondes selon système
Volume	très grands lots	flux continu
Exemple	rapport quotidien	alerte fraude
Complexité	souvent plus simple	gestion événements / état
Critère clé	fenêtre de traitement	temps de réaction

Exemple IoV — même donnée, deux usages



V. Data as a strategic asset

La valeur ne vient pas seulement du volume : elle dépend de la capacité à transformer la donnée en information exploitable et de confiance.

1 - Data as a strategic asset — définition

Actif stratégique

Une donnée devient stratégique lorsqu'elle contribue de façon durable à la compréhension, à la décision, à l'optimisation ou à l'innovation de l'organisation.

Exemple

Historique clients + transactions + comportement web → segmentation, personnalisation, prévision de demande.



Disponibilité

La donnée doit être accessible.



Confiance

Qualité + gouvernance + sécurité.



Usage

Elle doit répondre à un besoin.

Pourquoi « beaucoup de données » ne signifie pas « beaucoup de valeur » ?

- Des données dupliquées ou contradictoires peuvent ralentir la décision.
- Des données sans métadonnées peuvent être difficiles à découvrir et comprendre.
- Des données non gouvernées peuvent être difficiles à partager légalement et correctement.
- Des données non représentatives peuvent dégrader un modèle IA.
- Des données indisponibles au moment nécessaire ne permettent pas de soutenir un workload critique.

Principe

La valeur dépend du contexte, de la qualité, de l'accès et de l'usage.

Qualité des données ≠ même qualité pour tous les usages

BI / Reporting

Une donnée peut être nettoyée et agrégée pour produire un indicateur stable.

Ex. : corriger des formats de date et harmoniser les catégories produit.

IA / ML

La représentativité devient essentielle : certaines valeurs rares, erreurs ou cas atypiques peuvent être utiles selon le cas d'usage.

Question d'architecte

« Quelle qualité est nécessaire pour CE workload ? »

2 - Gouvernance, métadonnées et observabilité — première introduction



Exemple :

Une donnée peut être **accessible** mais mal documentée, documentée mais **non fiable**, fiable mais **indisponible**.

Concept	Question principale
Gouvernance	Qui peut faire quoi et selon quelles règles ?
Métadonnées	Que représente cette donnée ?
Observabilité	Que se passe-t-il avec cette donnée/pipeline ?

VI. Data-driven vs AI-driven organizations

L’architecture devient le socle commun de la BI, du ML et des nouveaux systèmes d’IA.

1 - Data-driven organization — définition

Définition

Une organisation data-driven utilise systématiquement les données et l'analytique pour éclairer ses décisions et améliorer ses opérations.

Exemple

Dashboard commercial → baisse des ventes dans une région → analyse des causes → action corrective.

- KPI et tableaux de bord.
- Analyse descriptive et diagnostique.
- Culture de décision fondée sur les données.

Data-driven

La donnée aide principalement

l'humain à décider.

2 - AI-driven organization — définition

Définition

Une organisation AI-driven intègre des modèles d'IA dans certains processus afin de prédire, recommander, classer, automatiser ou générer.

Exemple

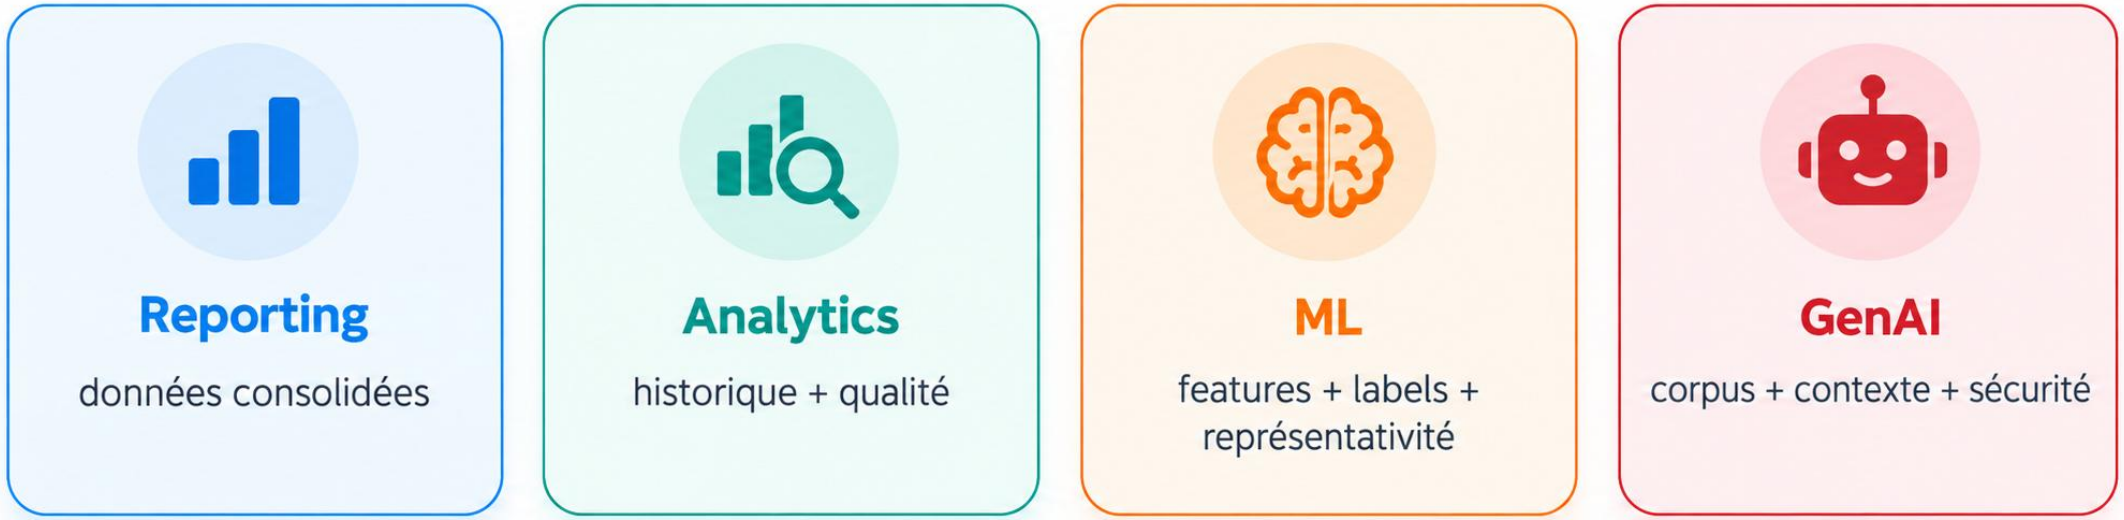
Prévoir la demande → recommander un produit → détecter une anomalie → générer une réponse.

- ML traditionnel.
- IA générative.
- Automatisation et assistance intelligente.

AI-driven

La donnée alimente également **un système capable de prédire, recommander, classer, générer ou automatiser**.

3 - Du reporting à l'IA — exigences croissantes

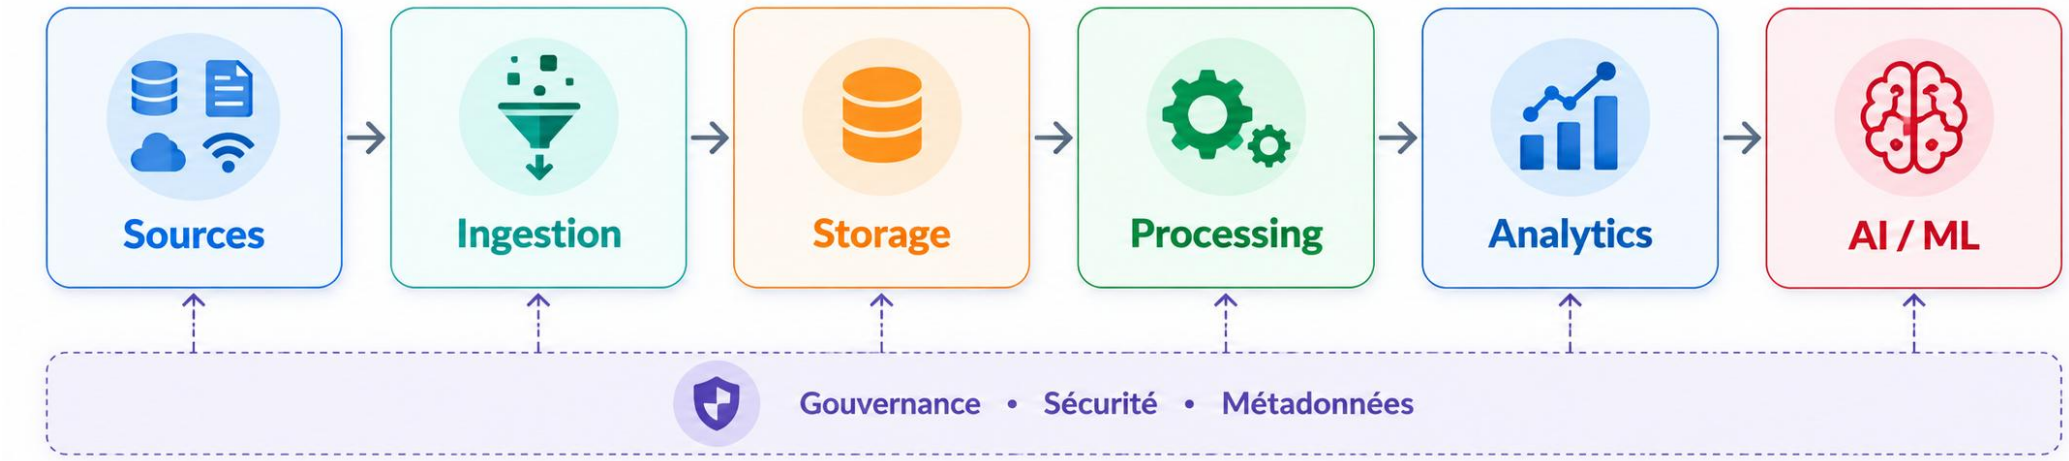


Point clé

Plus l'usage est avancé, plus les exigences sur la donnée deviennent explicites.

VII. Présentation d’une architecture moderne de données

1. Présentation d'une architecture moderne de données

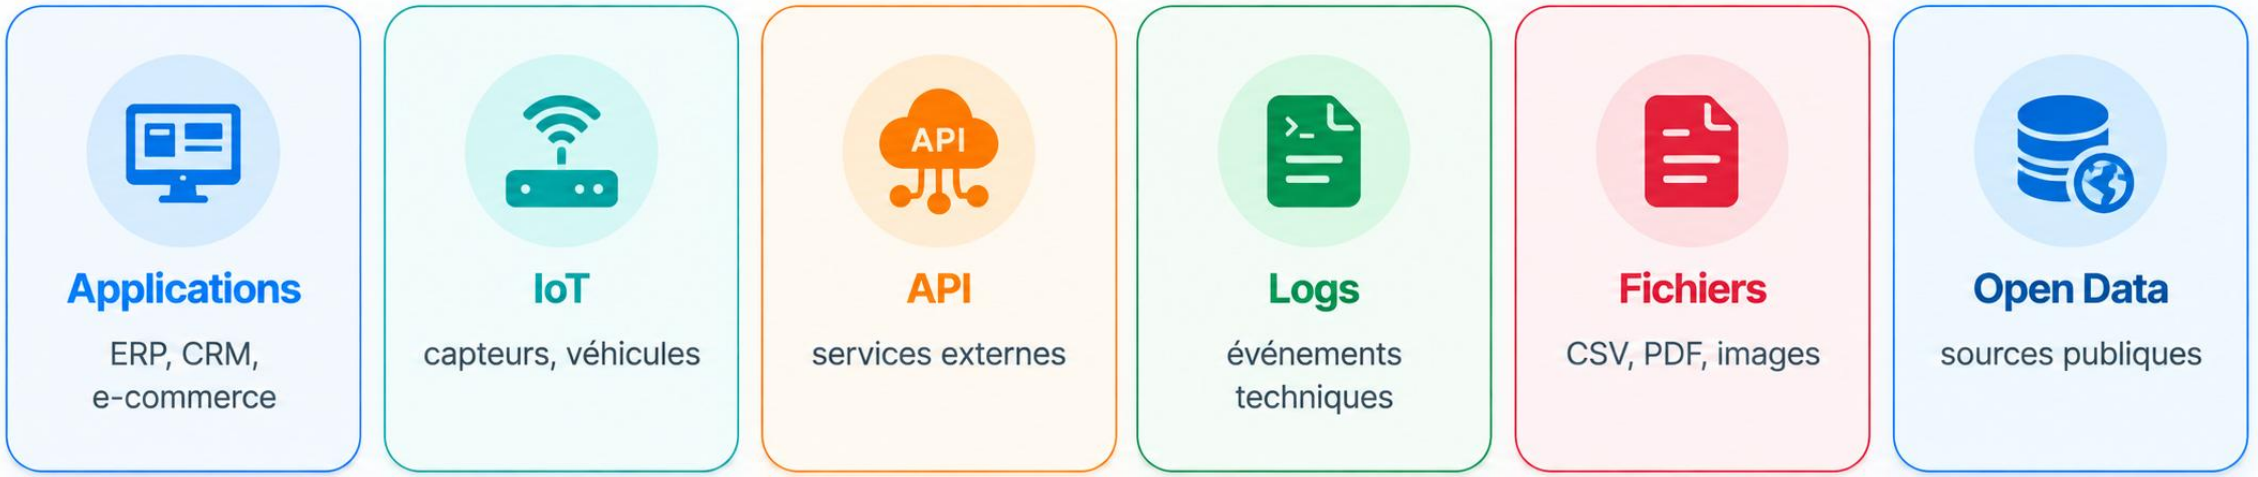


Couche transverse

Gouvernance • sécurité • métadonnées • qualité • traçabilité • observabilité

La gouvernance, la sécurité, les métadonnées, la qualité et l'observabilité ne sont pas une étape du pipeline : elles traversent toute l'architecture.

2 — Sources : d’où viennent les données ?



Question

Les sources n’ont ni le même format, ni la même fréquence, ni la même qualité.

3 — Ingestion : comment faire entrer les données ?



Objectif

Acheminer la donnée sans perdre son contexte et sa traçabilité.

4 — Storage : où conserver les données ?



Question

Quel stockage répond au workload, au coût, à la latence et au cycle de vie ?

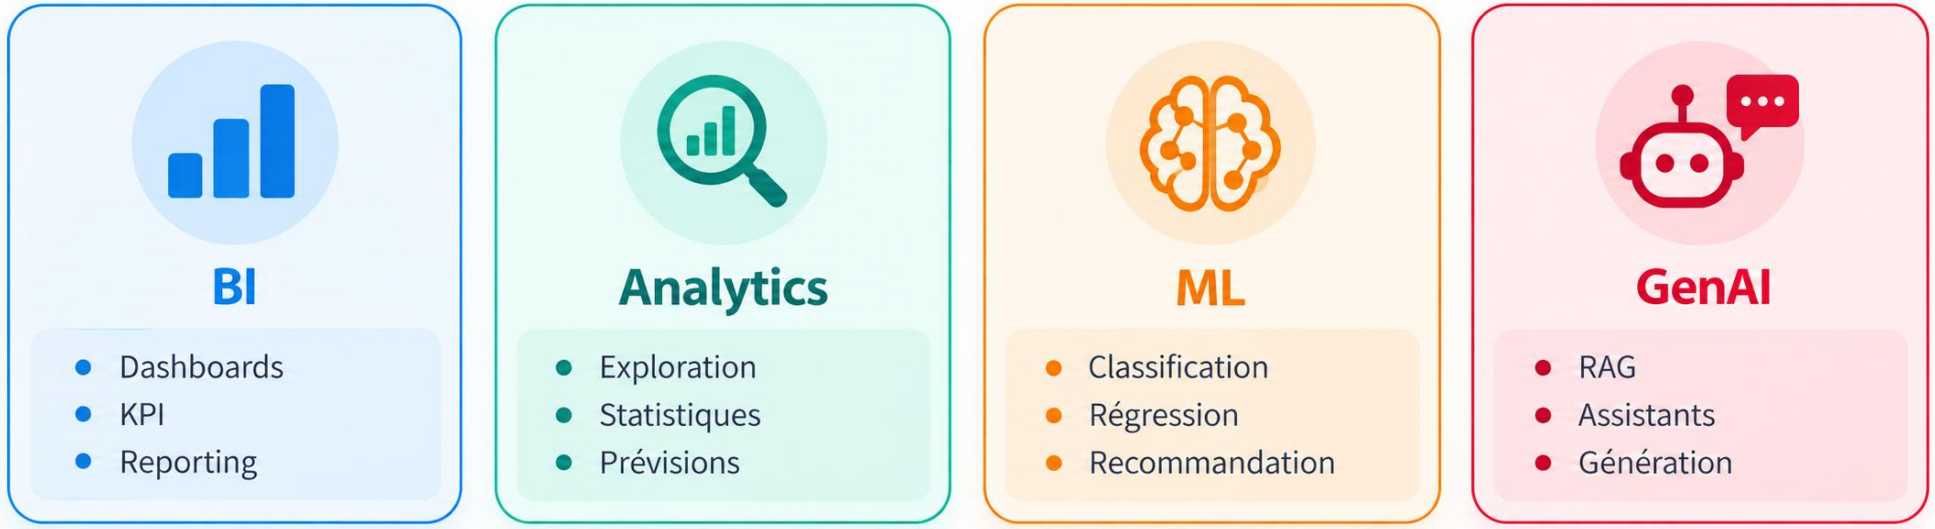
5 — Processing : que fait-on avec les données ?



Processing

Rendre les données adaptées à un usage précis.

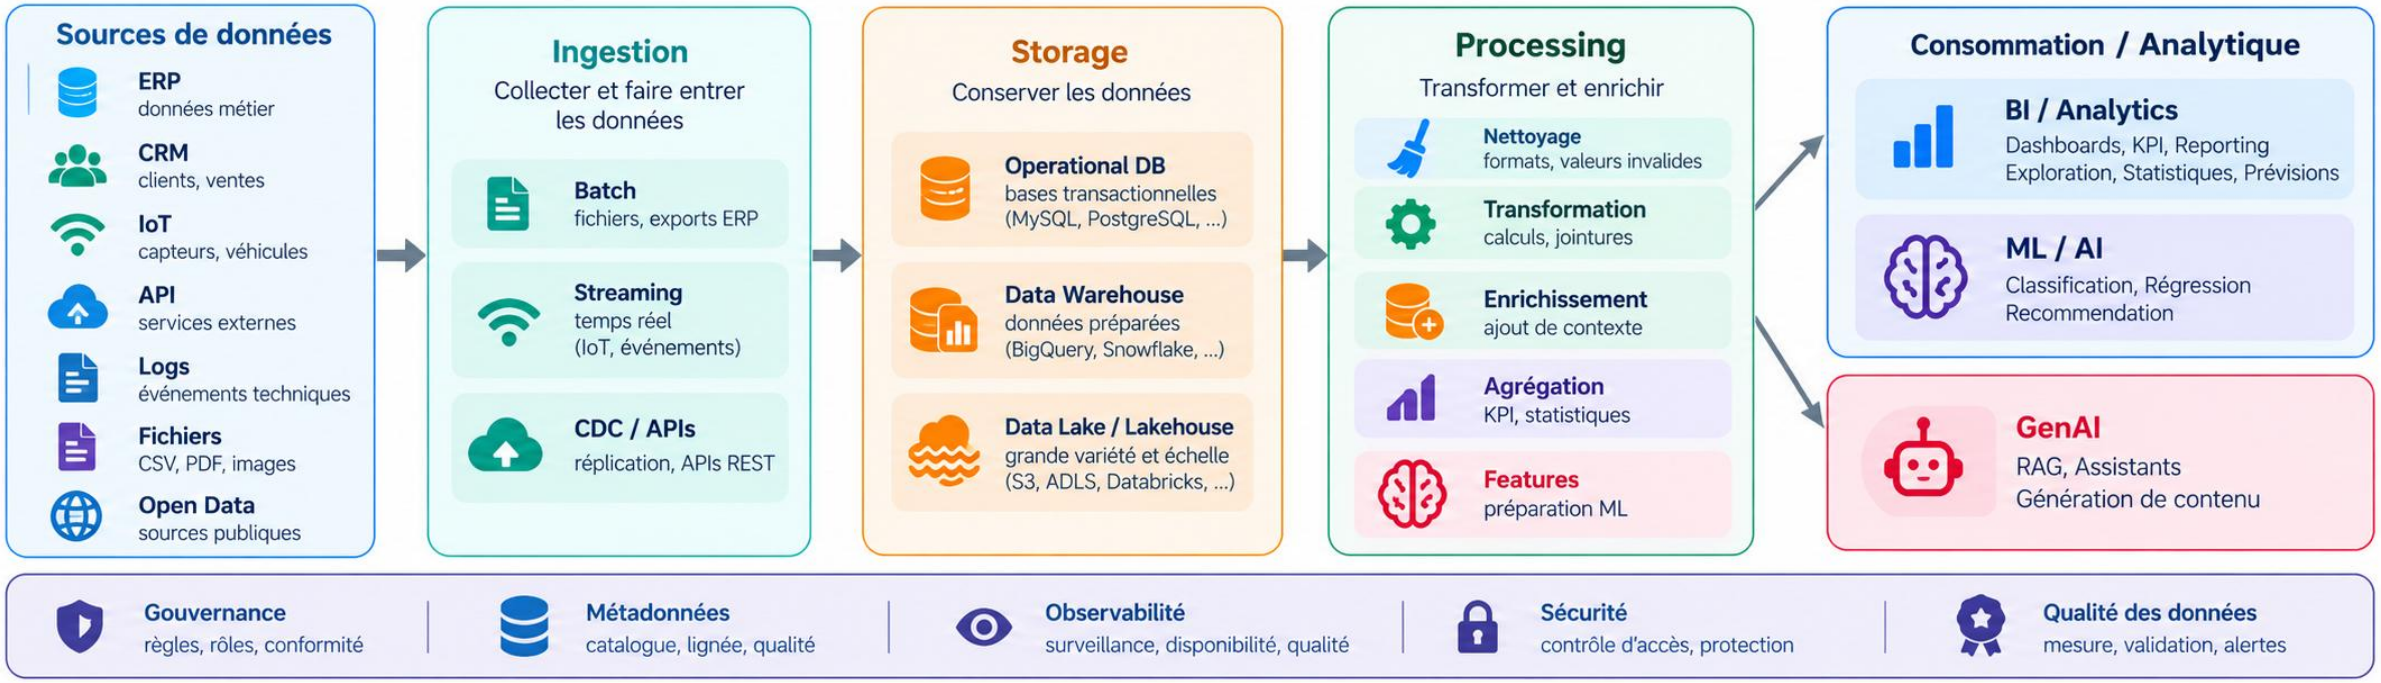
6 — Analytics / AI : qui consomme les données ?



Principe

Plusieurs consommateurs peuvent partager un même socle de données gouverné.

7 - Architecture moderne — vue complète



Étude de cas

Architecture traditionnelle → architecture moderne : comprendre la transformation par les contraintes.

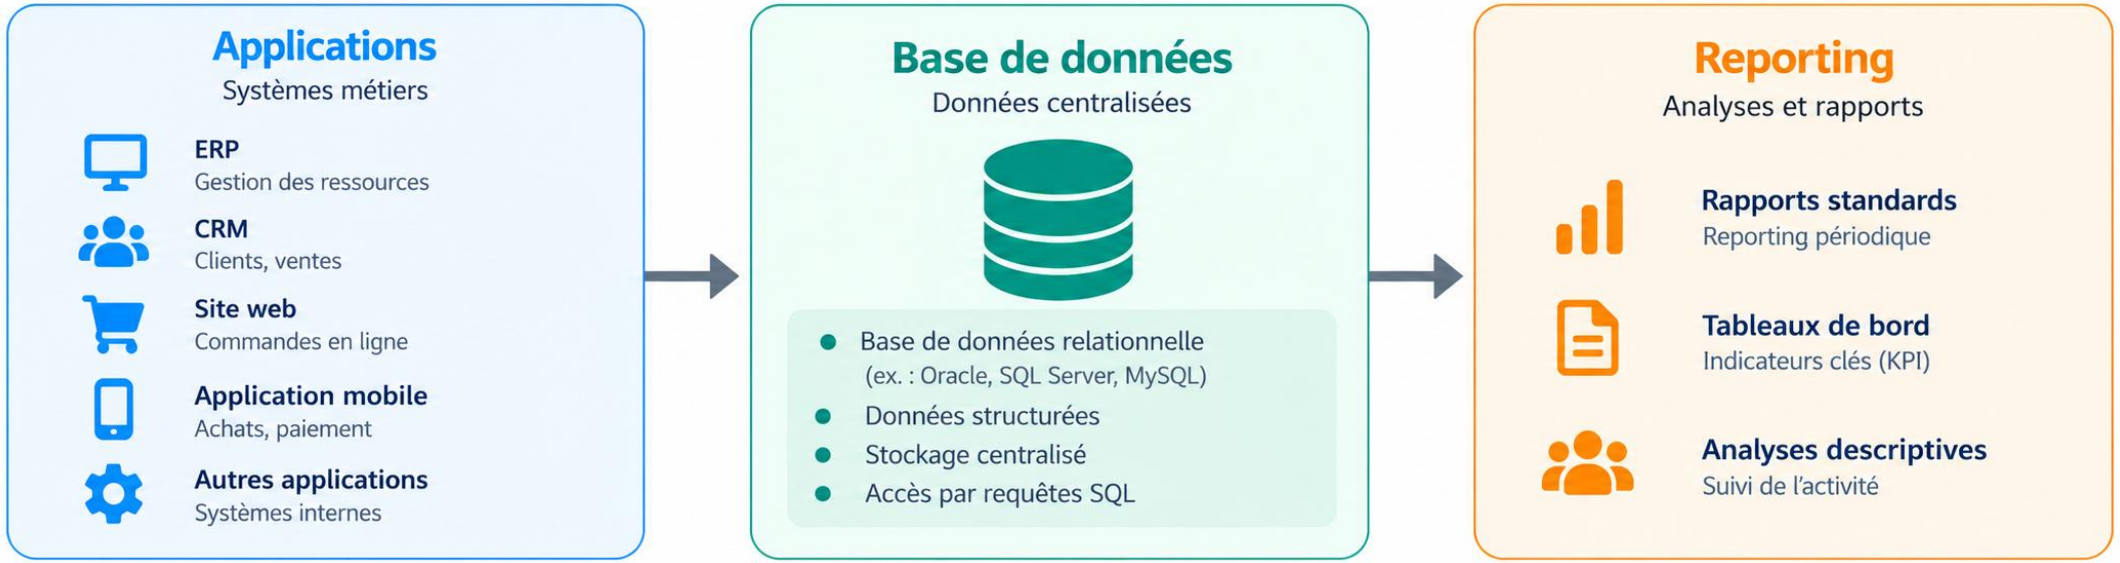
Cas — entreprise e-commerce



Question

Quelle architecture faut-il construire pour supporter ces usages sans multiplier les copies ?

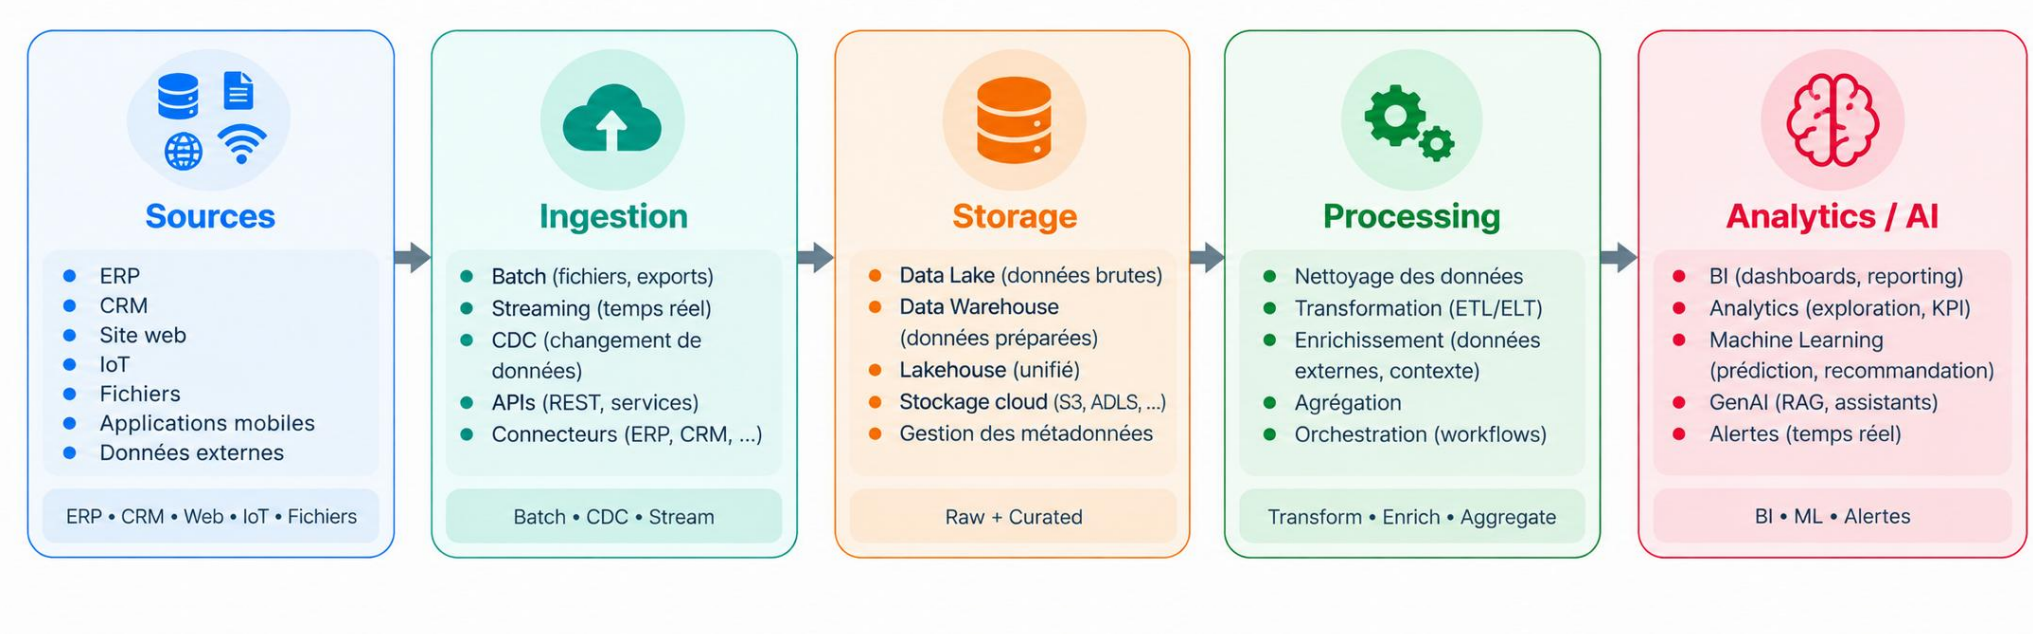
Cas — architecture traditionnelle



Problèmes potentiels

Le reporting peut dépendre directement de la base transactionnelle ; les nouvelles sources ne trouvent pas naturellement leur place ; l'IA nécessite davantage de données préparées.

Cas — architecture moderne proposée



Gouvernance transverse

Catalogue • qualité • sécurité • accès • lineage • observabilité

Cas — décision d’architecture : questions à poser

- Quel est le volume quotidien et sa croissance ?
- Quel est le délai acceptable entre production et utilisation ?
- Quelles sources sont structurées, semi-structurées ou non structurées ?
- Quelles données doivent être conservées brutes ?
- Quels consommateurs ont besoin de données fraîches ?
- Quelles contraintes de sécurité, confidentialité et conformité ?
- Quel compromis coût / performance / flexibilité / simplicité ?

TD — architecture IoT / Edge

- 20 000 capteurs : température, vibration, énergie.
- Certaines alertes doivent être traitées en moins de 2 secondes.
- Les historiques sont conservés pour analyse et ML.
- Certains sites peuvent perdre temporairement la connexion cloud.
- Concevoir : Edge + ingestion + streaming + stockage + processing + analytics.
- Bonus : que doit rester local pendant une coupure ?