DATA ANALYTICS

Fondements de la visualisation

Master DSBD & Master IA
Pr Nawal SAEL

PRÉSENTATION

Objectifs du module

1 Comprendre
les principes de perception visuelle et de conception d'une visualisation

2 Analyser
et critiquer une visualisation avec le cadre What – Why – How

3 Réaliser
une analyse visuelle interactive (Tableau, Python)

4 Raisonner
en analytique visuelle : de l'exploration des données à la décision

À retenir Une visualisation est un outil pour accomplir une tâche, pas une décoration.

PRÉSENTATION

Plan du module

Partie 1 · Visualisation

- Ch. 1 Pourquoi visualiser ?
- Ch. 2 What : abstraction des données
- Ch. 3 Why : abstraction des tâches
- Ch. 4 Valider une visualisation
- Ch. 5 Marques et canaux
- Ch. 6 Organiser les tables
- Ch. 7 Données spatiales, réseaux
- Ch. 8 Couleur
- Ch. 9 Manipuler, vues multiples
- Ch. 10 Réduire, focus + contexte

Partie 2 · Analytique

- De la visualisation à l'analytique visuelle
- Analyse exploratoire des données (EDA)
- Réduction de dimension et clustering
- Séries temporelles
- Tableaux de bord et storytelling
- Visualiser pour expliquer les modèles d'IA

Partie 3 · Études de cas

- Études de cas d'aide à la décision
- Présentation des projets

PRÉSENTATION

Organisation et évaluation

Travaux pratiques et projet

- **TP :** Tableau (licence académique à demander) et Python
- **Projet :** en binôme, sur un jeu de données réel
- **Rendu :** visualisation interactive sous Tableau + mise en œuvre en Python
- **Livrable :** présentation et démonstration

Évaluation

- Travaux pratiques
- Projet et présentation
- Examen écrit

À retenir Justifiez chaque choix graphique avec le vocabulaire du cours : c'est ce qui est évalué.

CHAPITRE 1

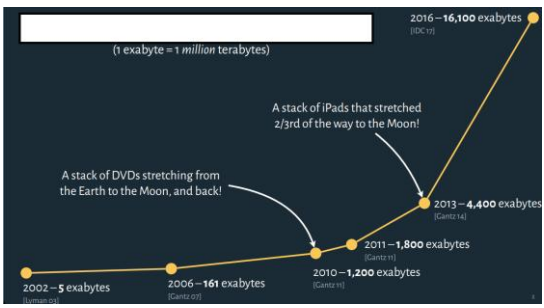
Pourquoi visualiser ?

Objectifs : à la fin de ce chapitre, vous saurez…

- définir un système de visualisation (Munzner) ;
- expliquer quand la visualisation est utile… et quand elle ne l'est pas ;
- citer les ressources limitées qui contraignent toute conception ;
- présenter le cadre What – Why – How.

CH. 1 · CONTEXTE

Les données explosent… notre attention, non



Volume mondial de données (estimations IDC)

- Comment donner du sens à ces données ?
- Comment les utiliser pour décider ?
- Comment ne pas être submergé ?

Le défi

Transformer les données en connaissance (découverte, compréhension) pour qu'elles deviennent utiles.

Ce qui ne grandit pas : le temps et l'attention de la personne qui doit comprendre ces données et décider. C'est cette asymétrie qui justifie la visualisation et, plus largement, la data analytics.

CH. 1 · DÉFINITION

Définition de la visualisation (Munzner)

Les systèmes de visualisation informatisés fournissent des représentations visuelles de jeux de données, conçues pour aider des personnes à accomplir des tâches plus efficacement. — T. Munzner, 2014

Représentations visuelles	Jeux de données	Des personnes	Des tâches	Plus efficacement
Ch. 5 · How	Ch. 2 · What	humain dans la boucle	Ch. 3 · Why	Ch. 4 · Validation

À retenir Toute la structure du cours est contenue dans cette définition.

CH. 1 · DÉFINITION

D'autres définitions, une même idée

1987

Visualisation scientifique

- Transformer le symbolique en géométrique pour « voir l'invisible » dans les simulations et les calculs.
- — McCormick, DeFanti & Brown

1999

Visualisation d'information

- « L'utilisation de représentations visuelles, interactives et informatisées de données abstraites pour amplifier la cognition. »
- — Card, Mackinlay &

2014

Vis centrée tâche

- Aider des personnes à accomplir des tâches plus efficacement.
- — Munzner

À retenir Visualisation (vis) ≠ analytique visuelle (visual analytics) : la seconde couple analyse automatique et visualisation.

CH. 1 · POURQUOI

Quand faut-il un humain dans la boucle ?

Pas besoin de vis

Une solution entièrement automatique est fiable et acceptable : le jugement humain n'est pas nécessaire.

La vis est utile quand…

- **Explorer :** la question est mal définie (quels gènes sont associés à une maladie ?)
- **Construire un algorithme :** comprendre, déboguer, régler, puis surveiller un modèle déployé
- **Valider un modèle :** vérifier qu'il correspond vraiment aux données
- **Communiquer :** présenter un résultat, convaincre un décideur

À retenir La vis aide l'humain, elle ne le remplace pas.

CH. 1 · POURQUOI

Les statistiques résumées ne suffisent pas : Anscombe

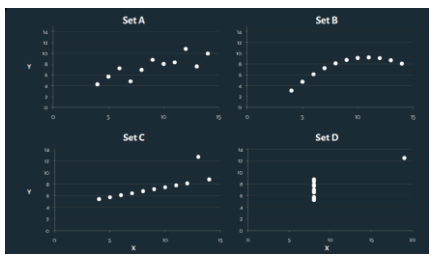
Set A		Set B		Set C		Set D	
X	Y	X	Y	X	Y	X	Y
10	8.04	10	9.14	10	7.46	8	6.58
8	6.95	8	8.14	8	6.77	8	5.76
13	7.58	13	8.74	13	12.74	8	7.71
9	8.81	9	8.77	9	7.11	8	8.84
11	8.33	11	9.26	11	7.81	8	8.47
14	9.96	14	8.1	14	8.84	8	7.04
6	7.24	6	6.13	6	6.08	8	5.25
4	4.26	4	3.1	4	5.39	19	12.5
12	10.84	12	9.11	12	8.15	8	5.56
7	4.82	7	7.26	7	6.42	8	7.91
5	5.68	5	4.74	5	5.73	8	6.89

Summary Statistics
$u_X = 9.0$ $\sigma_X = 3.317$
$u_Y = 7.5$ $\sigma_Y = 2.03$

Linear Regression
$Y = 3 + 0.5X$
$R^2 = 0.67$

[Anscombe 1973]

Mêmes statistiques résumées…

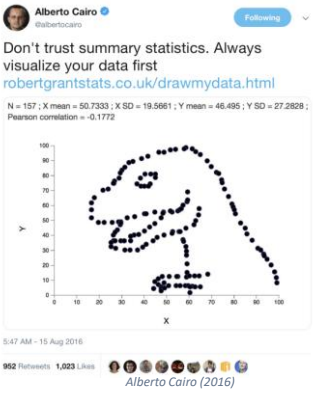


…données très différentes (Anscombe, 1973)

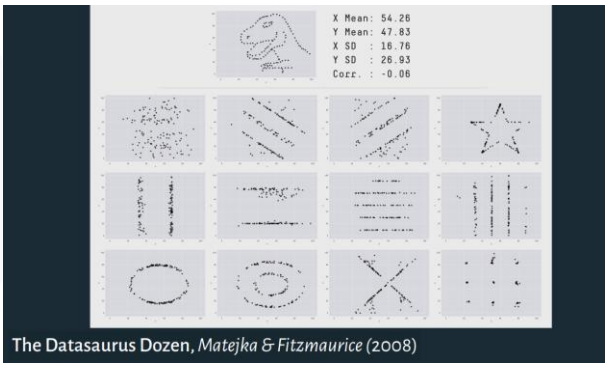
À retenir Les résumés perdent de l'information : regardez toujours vos données avant de modéliser.

CH. 1 · POURQUOI

Toujours visualiser d'abord : le Datasaurus



Alberto Cairo (2016)



The Datasaurus Dozen — Matejka & Fitzmaurice (2017)

CH. 1 · POURQUOI

Pourquoi la vue ? Un canal à très haut débit

Haut débit

Une grande partie du traitement visuel est pré-attentive : rapide, parallèle, sans effort conscient.

Mémoire externe

L'image retient les valeurs à notre place : on décharge la mémoire de travail sur la perception.

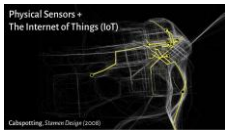
Organisation spatiale

Placer l'information dans l'espace accélère la recherche et la reconnaissance.

À retenir Visualiser, c'est déplacer une partie du travail cognitif vers la perception.

CH. 1 · EXEMPLES

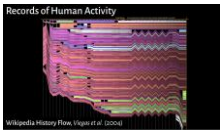
Des domaines d'application très variés



Mobilité, IoT : Cabspotting (Stamen, 2008)



Réseaux sociaux : amitiés Facebook (2010)



Texte, collaboration : History Flow (Viégas et al., 2004)



Géographie : carte choroplèthe

CH. 1 · POURQUOI

Une compétence clé

> *The ability to take data — to be able to understand it, to process it, to extract value from it, to visualize it, to communicate it — that's going to be a hugely important skill in the next decades.*

Hal Varian, économiste en chef de Google — The McKinsey Quarterly, janvier 2009

CH. 1 · INTERACTION

Pourquoi l'interactivité ?

- Une vue statique ne montre qu'un aspect des données ; elle ne suffit que pour des données et des tâches très simples.
- Données volumineuses ou questions multiples : l'interaction (l'action de l'utilisateur modifie la vue) permet de nombreuses requêtes.



À retenir L'interaction lève la limite d'une vue unique : une vis = une conversation avec les données.

CH. 1 · CONTRAINTES

Trois ressources limitées

Toute conception de visualisation est un compromis entre trois ressources limitées

Calcul

- Temps de traitement
- Mémoire du système
- Latence de l'interaction

Humain

- Attention limitée
- Mémoire de travail limitée

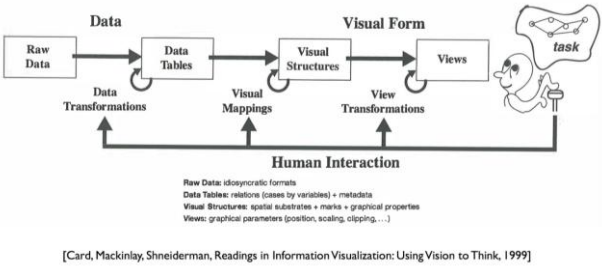
Affichage

- Les pixels : ressource la plus contraignante
- Densité d'information : entre fouillis et espace gaspillé

À retenir Concevoir, c'est arbitrer entre calcul, attention humaine et pixels.

CH. 1 · PROCESSUS

Le pipeline de la visualisation



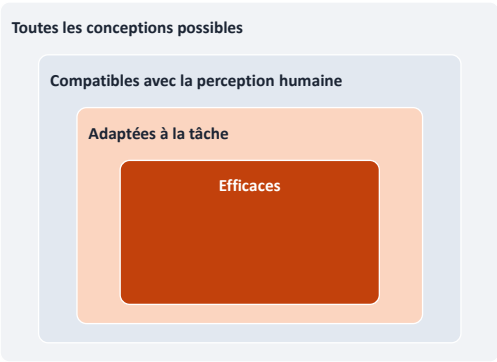
[Card, Mackinlay, Shneiderman, Readings in Information Visualization: Using Vision to Think, 1999]

Card, Mackinlay & Shneiderman (1999)

- **Transformations de données :** nettoyer, filtrer, dériver
- **Mappings visuels :** choisir marques et canaux
- **Transformations de vue :** zoomer, naviguer, filtrer
- **Interaction :** l'humain agit à chaque étape

CH. 1 · CONCEPTION

Pourquoi concevoir une vis est difficile



- L'espace de conception est immense.
- La plupart des conceptions sont inefficaces : mal adaptées à la perception, ou à la tâche.
- Très peu sont vraiment efficaces.
- D'où le besoin d'un cadre systématique pour choisir et justifier.

C'est l'objet du cadre What–Why–How.

CH. 1 · CADRE

Le cadre d'analyse : What – Why – How



What ?	**Quelles données sont montrées ?** Abstraction des données ·
Why ?	**Pourquoi l'utilisateur regarde-t-il ?** Abstraction des tâches ·
How ?	**Comment la vis est-elle construite ?** Idiomes : encoder, manipuler, facetter, réduire

CH. 1 · VÉRIFIER

Testez-vous

Q1 Un algorithme classe automatiquement les chèques avec 99,9 % de fiabilité. Faut-il une visualisation ? Et pendant sa mise au point ?

Q2 Deux jeux de données ont la même moyenne, la même variance et la même corrélation. Peut-on conclure qu'ils sont similaires ?

Q3 Citez les trois ressources limitées d'une visualisation et donnez un exemple de compromis.

WHAT

Abstraction des données

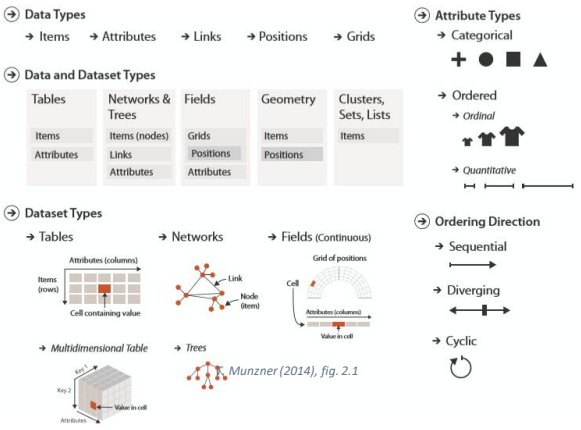
Objectifs :

- identifier items, attributs, liens, positions et grilles ;
- reconnaître les types de jeux de données : tables, réseaux, champs, géométrie ;
- classer un attribut : catégoriel, ordinal, quantitatif ;
- distinguer type de données et sémantique (clés, valeurs, temps).

21

CH. 2 · WHAT

Vue d'ensemble de l'abstraction des données



Munzner (2014), fig. 2.1

- **Types de données :** items, attributs, liens, positions, grilles
- **Jeux de données :** tables, réseaux, champs, géométrie
- **Attributs :** catégoriels ou ordonnés
- **Disponibilité :** statique ou dynamique

22

CH. 2 · WHAT

Item et attribut

Exemple item (élément)/attribut



Item (élément)

Entité individuelle, discrète. Ex. : un patient, une voiture, une commande.

Attribut

Propriété mesurée ou observée. Ex. : taille, tension artérielle, vitesse.

À retenir Ligne = item · colonne = attribut · cellule = valeur. En ML : observation et feature.

CH. 2 · WHAT

Liens, positions et grilles

— Lien

- Relation entre deux items
- Un item d'un réseau est un nœud
- Ex. : amitié sur un réseau social, interaction entre gènes

✦ Position

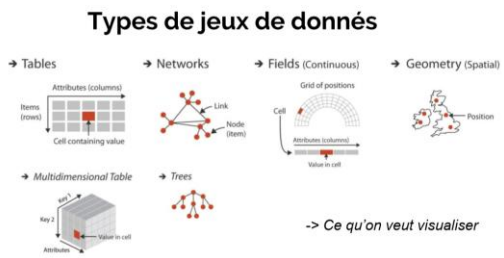
- Donnée spatiale en 2D ou 3D
- Ex. : latitude et longitude d'une station météo

Grille

- Échantillonnage de données continues
- Relations géométriques et topologiques entre cellules
- Ex. : maillage de mesures de température

CH. 2 · WHAT

Les types de jeux de données



- **Tables :** lignes et colonnes (le plus répandu)
- **Réseaux, arbres :** nœuds et liens
- **Champs :** valeurs sur une grille continue
- **Géométrie :** formes avec positions
- **Ensembles, listes :** groupes d'items

À retenir Un même phénomène peut relever de plusieurs types : un réseau se stocke aussi en deux tables.

CH. 2 · TABLES

Tables

A	B	C	S	T	U
Order ID	Order Date	Order Priority	Product Container	Product Base Margin	Ship Date
3	10/14/06	5-Low	Large Box	0.8	10/21/06
6	2/21/08	4-Not Specified	Small Pack	0.55	2/22/08
32	7/16/07	2-High	Small Pack	0.79	7/17/07
32	7/16/07	2-High	Jumbo Box	0.72	7/17/07
32	7/16/07	2-High	Medium Box	0.6	7/18/07
32	7/16/07	2-High	Medium Box	0.65	7/18/07
35	10/23/07	4-Not Specified	Wrap Bag	0.52	10/24/07
35	10/23/07	4-Not Specified	Small Box	0.58	10/25/07
36	11/3/07	1-Urgent	Small Box	0.55	11/3/07
65	3/18/07	1-Urgent	Small Pack	0.49	3/19/07
66	1/20/05	5-Low	Wrap Bag	0.56	1/20/05
69	6/4/05	4-Not Specified	Small Pack	0.44	6/6/05
69	6/4/05	4-Not Specified	Wrap Bag	0.6	6/6/05
70	12/18/06	5-Low	Small Box	0.59	12/23/06
70	12/18/06	5-Low	Wrap Bag	0.82	12/23/06
96	4/17/05	2-High	Small Box	0.55	4/19/05
97	1/29/06	3-Medium	Small Box	0.38	1/30/06
129	11/19/08	5-Low	Small Box	0.37	11/28/08
130	5/8/08	2-High	Small Box	0.37	5/9/08
130	5/8/08	2-High	Medium Box	0.38	5/10/08
130	5/8/08	2-High	Small Box	0.6	5/11/08
132	6/11/06	3-Medium	Medium Box	0.6	6/12/06
132	6/11/06	3-Medium	Jumbo Box	0.69	6/14/06
134	5/1/08	4-Not Specified	Large Box	0.82	5/3/08
135	10/21/07	4-Not Specified	Small Pack	0.64	10/23/07
166	9/12/07	2-High	Small Box	0.55	9/14/07
193	8/8/06	1-Urgent	Medium Box	0.57	8/10/06
194	4/5/08	3-Medium	Wrap Bag	0.42	4/7/08

Record / Item

Une ligne = un item (enregistrement)

A	B	C	S	T	U
Order ID	Order Date	Order Priority	Product Container	Product Base Margin	Ship Date
3	10/14/06	5-Low	Large Box	0.8	10/21/06
6	2/21/08	4-Not Specified	Small Pack	0.55	2/22/08
32	7/16/07	2-High	Small Pack	0.79	7/17/07
32	7/16/07	2-High	Jumbo Box	0.72	7/17/07
32	7/16/07	2-High	Medium Box	0.6	7/18/07
32	7/16/07	2-High	Medium Box	0.65	7/18/07
35	10/23/07	4-Not Specified	Wrap Bag	0.52	10/24/07
35	10/23/07	4-Not Specified	Small Box	0.58	10/25/07
36	11/3/07	1-Urgent	Small Box	0.55	11/3/07
65	3/18/07	1-Urgent	Small Pack	0.49	3/19/07
66	1/20/05	5-Low	Wrap Bag	0.56	1/20/05
69	6/4/05	4-Not Specified	Small Pack	0.44	6/6/05
69	6/4/05	4-Not Specified	Wrap Bag	0.6	6/6/05
70	12/18/06	5-Low	Small Box	0.59	12/23/06
70	12/18/06	5-Low	Wrap Bag	0.82	12/23/06
96	4/17/05	2-High	Small Box	0.55	4/19/05
97	1/29/06	3-Medium	Small Box	0.38	1/30/06
129	11/19/08	5-Low	Small Box	0.37	11/28/08
130	5/8/08	2-High	Small Box	0.37	5/9/08
130	5/8/08	2-High	Medium Box	0.38	5/10/08
130	5/8/08	2-High	Small Box	0.6	5/11/08
132	6/11/06	3-Medium	Medium Box	0.6	6/12/06
132	6/11/06	3-Medium	Jumbo Box	0.69	6/14/06
134	5/1/08	4-Not Specified	Large Box	0.82	5/3/08
135	10/21/07	4-Not Specified	Small Pack	0.64	10/23/07
166	9/12/07	2-High	Small Box	0.55	9/14/07
193	8/8/06	1-Urgent	Medium Box	0.57	8/10/06
194	4/5/08	3-Medium	Wrap Bag	0.42	4/7/08

Field / Dimension / Attribute

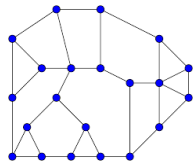
Une colonne = un attribut (champ, dimension)

À retenir Table multidimensionnelle : plusieurs clés identifient un item (produit × magasin × mois).

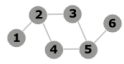
CH. 2 · RÉSEAUX

Réseaux et arbres

- **Nœud :** un item ; lien : relation entre deux nœuds
- **Attributs :** sur les nœuds comme sur les liens
- **Stockage :** deux tables, nœuds et liens
- **Types :** orienté / non orienté, acyclique (DAG), connexe, planaire
- **Arbre :** graphe connexe sans cycle ; chaque enfant a un seul parent



Graphe planaire

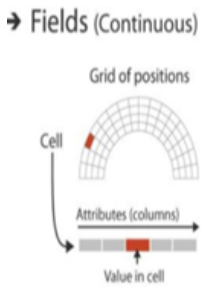


Graphe non orienté

À retenir Ex. : réseau social (personnes, amitiés), réseau d'interaction génique.

CH. 2 · CHAMPS

Champs (fields) : des données continues

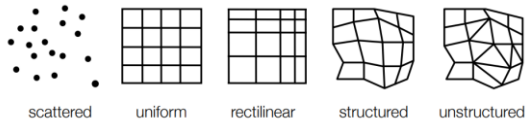


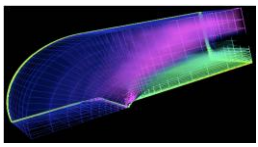
- Valeurs d'attributs associées aux cellules d'une grille
- Domaine continu : on peut toujours mesurer entre deux points (échantillonnage, interpolation)
- **Champ spatial :** cellules fondées sur des positions (imagerie médicale, météo, simulation d'écoulement)
- **Ex. :** densité des tissus mesurée en chaque point d'un volume 3D

À retenir Table : items discrets · champ : phénomène continu échantillonné.

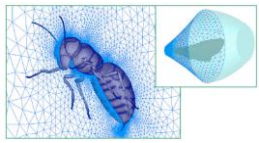
CH. 2 · CHAMPS

Grilles d'échantillonnage





Grille structurée (curvilinéaire)



Grille non structurée

CH. 2 · CHAMPS

Champs scalaires, vectoriels et tensoriels

Scalaire

- Une valeur par point
- Ex. : température en chaque point d'une pièce

Vectoriel

- Direction + magnitude
- Ex. : vitesse de l'air à un instant donné

Tensoriel

- Tableau de valeurs (ex. : 3×3 = 9)
- Ex. : contrainte mécanique ; représentée par un ellipsoïde

À retenir La complexité de la valeur en chaque point détermine l'encodage : couleur, flèche, glyphe.

CH. 2 · GÉOMÉTRIE

Géométrie et topologie

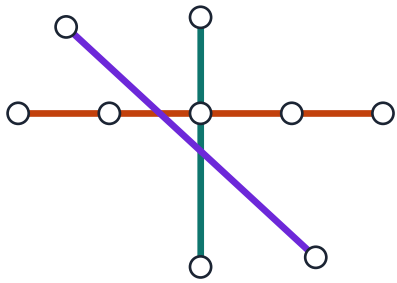
Géométrie : où ?

Forme et position explicite des items : points, lignes, surfaces, volumes. Ex. : frontières des communes.

Topologie : quoi est relié à quoi ?

Structure, connectivité. Y a-t-il des trous ? Tout est-il relié ? Peut-on séparer en parties ?

Un plan de métro est topologique : distances fausses, connexions exactes



CH. 2 · WHAT

Autres formes de données

¶ Texte et logs

- Document : séquence ordonnée de mots ; collection = corpus
- Sac de mots : on compte les mots, le texte devient une table
- Logs : conçus pour être lus par une machine ; à analyser avant de visualiser

≋ Statique ou dynamique

- Fichier statique : chargé en entier
- Flux dynamique : capteurs, transactions, réseaux sociaux
- Défi : mettre à jour la vue sans désorienter l'utilisateur

À retenir Avant de visualiser du texte ou des logs, on les transforme presque toujours en table.

CH. 2 · ATTRIBUTS

Types d'attributs

Type	Ordre ?	Exemples
Catégoriel (nominal)	Aucun	fruit, pays, genre musical, identifiant de gène
Ordinal	Ordre, sans distance	petit / moyen / grand ; A+, A++, A+++ ; mois
Quantitatif	Ordre et distance	taille, poids, prix, température

Direction de l'ordre

Séquentielle
min → max (altitude)

Divergente
← 0 → (écart à la moyenne)

Cyclique
revient au début (jours, heures)

Cette direction guide plus tard le choix des palettes de couleurs)

CH. 2 · ATTRIBUTS

Les échelles de mesure (Stevens, 1946)

Échelle	Opérations	Exemple	Ce qu'on peut dire
Nominale	= ≠	couleur des yeux	« différent de »
Ordinale	= ≠ < >	classe A+, A++, A+++	« meilleur que »
Intervalle (zéro arbitraire)	= ≠ < > + −	°C, dates	« 10 ans d'écart »
Ratio (zéro absolu)	= ≠ < > + − × ÷	poids, longueur	« deux fois plus lourd »

À retenir 20 °C n'est pas « deux fois plus chaud » que 10 °C : le zéro des °C est arbitraire.

CH. 2 · SÉMANTIQUE

Type de données ≠ sémantique

Modèle de données
flottants : 32.5, 54.0, −17.3

→

Sémantique
c'est une température

→

Type pour la tâche

- **Clé :** attribut indépendant qui identifie un item (identifiant, date)
- **Valeur :** attribut dépendant (montant, mesure)

Quantitatif : valeur continue

Ordinal : chaud · tiède · froid · glacé

Nominal : brûlé / pas brûlé

À retenir C'est la tâche, et non le type informatique, qui décide comment traiter un attribut.

CH. 2 · SÉMANTIQUE

Hiérarchies et temps

Attributs hiérarchiques

- **Temps :** jour → semaine → mois → saison (cours boursiers)
- **Espace :** code postal → ville → région → pays
- Agréger ou détailler à chaque niveau (drill-down)

Le temps : clé ou valeur ?

- **Clé :** positions d'animaux mesurées chaque seconde → données variant dans le temps
- **Valeur :** heure de départ et durée de courses de chevaux → valeurs temporelles

À retenir Le temps a une structure hiérarchique et périodique : il mérite un traitement à part.

CH. 2 · EXERCICE

Exercice : abstraire un jeu de données

Q1 Fichier de ventes : n° de commande, date, client, ville, catégorie de produit, priorité (basse, moyenne, haute), quantité, montant. Identifiez items, clés, attributs, et le type de chaque attribut.

Q2 Données d'accéléromètre d'un smartphone, 50 mesures par seconde sur 3 axes : quel type de jeu de données ? Le temps est-il une clé ou une valeur ?

Q3 Un fichier de citations entre articles scientifiques : quel type de jeu de données ? Comment le stocker en tables ?

WHY

Abstraction des tâches

Objectifs : à la fin de ce chapitre, vous saurez…

- exprimer une tâche métier comme une paire {action, cible} ;
- distinguer analyser, rechercher et interroger ;
- expliquer pourquoi et comment dériver de nouveaux attributs.

CH. 3 · WHY

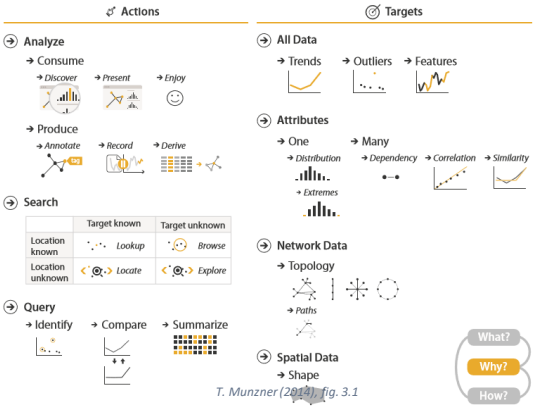
Pourquoi abstraire les tâches ?

Langage du domaine :		{ action, cible }
Biologie — Trouver les gènes sur-exprimés chez les patients malades	→	**{ comparer, distributions }**
Marketing — Repérer les clients qui risquent de partir	→	**{ identifier, valeurs aberrantes }**
Finance — Voir si deux actions évoluent ensemble	→	**{ découvrir, corrélation }**

À retenir Même abstraction de tâche → les mêmes idiomes peuvent servir, quel que soit le domaine.

CH. 3 · WHY

Vue d'ensemble : actions et cibles



T. Munzner (2014), fig. 3.1

- **Analyser :** consommer ou produire
- **Rechercher :** cible et localisation connues ?
- **Interroger :** un, quelques-uns, tous

- **Cibles :** tendances, valeurs aberrantes, distributions, corrélations, topologie, forme

CH. 3 · ACTIONS

Analyser : consommer ou produire

Consommer

- **Découvrir :** générer, vérifier des hypothèses
- **Présenter :** communiquer ce que l'on sait déjà
- **Apprécier :** consulter par curiosité

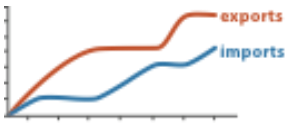
Produire

- **Annoter :** ajouter étiquettes et commentaires
- **Enregistrer :** garder la trace de l'analyse
- **Dériver :** calculer de nouveaux attributs

À retenir Une vis sert aussi à produire de l'information, par ex. étiqueter des données pour l'apprentissage.

CH. 3 · DÉRIVER

Dériver : ne dessinez pas seulement ce qu'on vous donne



Original Data

Données d'origine : exportations et importations



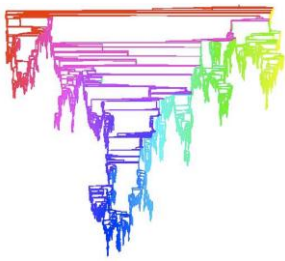
Derived Data

Attribut dérivé : balance = exportations – importations

À retenir Dériver un attribut transforme une comparaison difficile en lecture directe : c'est du feature engineering visuel.

CH. 3 · DÉRIVER

Exemple : le nombre de Strahler



Arbre complet



Les 5 000 nœuds de plus fort nombre de Strahler

À retenir Dériver une mesure d'importance, puis filtrer : on garde le squelette lisible de l'arbre.

CH. 3 · ACTIONS

Rechercher : que sait-on de la cible ?

	Localisation connue	Localisation inconnue
Cible connue	**Consulter (lookup)** prix d'un produit précis	**Localiser (locate)** un ami dans un réseau social
Cible inconnue	**Parcourir (browse)** les produits d'une catégorie	**Explorer (explore)** des valeurs aberrantes

À retenir Explorer est la recherche la plus exigeante : elle demande une vue d'ensemble.

CH. 3 · ACTIONS

Interroger : un, quelques-uns, tous

1 Identifier · un élément

Survoler un point pour voir ses valeurs

2–5 Comparer · quelques éléments

Ventes de deux régions côte à côte

∀ Résumer · tous les éléments

Distribution des salaires : histogramme

À retenir Un histogramme résume très bien… mais ne permet pas d'identifier un individu.

CH. 3 · CIBLES

Les cibles

Toutes les données

- Tendances
- Valeurs aberrantes
- Caractéristiques

Un attribut

- Distribution
- Extrêmes

Plusieurs attributs

- Dépendance
- Corrélation
- Similarité

Réseau · Spatial

- Topologie
- Chemins
- Forme

À retenir Formulez toujours une tâche par « verbe + cible » : résumer la distribution, comparer des tendances.

Pour décrire une tâche donnée : on choisit **une action par niveau.** Les trois niveaux sont trois facettes d'une même tâche, comme trois questions posées sur le même geste :

•*pourquoi* je regarde (analyser) ;
•*est-ce que je sais quoi chercher et où* (rechercher) ;
•*sur combien d'éléments* (interroger).
Quand l'analyste de l'exemple affiche ses dix ans de ventes, il est à la fois en train de découvrir, d'explorer et de résumer. Ce n'est pas « d'abord découvrir, puis explorer, puis résumer »

Au fil d'une analyse réelle : on **enchaîne plusieurs tâches**, et les choix changent à chaque fois. En reprenant le même analyste :

1. Il regarde toutes les ventes pour voir l'évolution : découvrir / explorer / **résumer**, cible : tendances.
2. Il remarque un pic anormal en mars 2024 et clique dessus : découvrir / **localiser** (il sait maintenant quoi chercher) / **identifier**, cible : valeur aberrante.
3. Il compare ce mois avec mars 2023 : découvrir / **lookup** / **comparer**.
4. Il prépare un graphique pour sa direction : **présenter**, ce qui change même le niveau le plus haut.

Une visualisation bien conçue doit donc souvent supporter plusieurs tâches, et permettre de passer facilement de l'une à l'autre : vue d'ensemble, puis zoom, puis détail.

CH. 3 · EXERCICE

Exercice : analyser une visualisation réelle

What	Items, attributs et leurs types, type de jeu de données, attributs dérivés ?
Why	Quelle tâche {action, cible} ? Pour quel public ?
How	Quelles marques, quels canaux, quelles interactions ?
Verdict	La vis est-elle efficace pour cette tâche ? Que changeriez-vous ?

Sources : Our World in Data · Financial Times · NYT The Upshot · Tableau Public

Solution - Proposition

What : les données

•**Type de jeu de données :** une table. Les **items** sont les pays, observés par année.

•**Attributs et leurs types :**

- PIB par habitant : quantitatif ;
- espérance de vie : quantitatif ;
- population : quantitatif ;
- continent : catégoriel ;
- année : quantitatif ordonné (temporel) ;
- nom du pays : catégoriel (sert de clé).

•**Attributs dérivés :** le PIB *par habitant* lui-même (PIB ÷ population), et le passage en échelle log, qui transforme visuellement l'attribut.

Solution - Proposition

Why : la tâche
•**Action :** découvrir / explorer / résumer, puis, en zoomant sur un pays, localiser / identifier ou comparer.
•**Cibles :**
- principale : la **corrélation** entre richesse et espérance de vie ;
- secondaires : les **valeurs aberrantes** (pays qui vivent plus ou moins longtemps que leur richesse le laisse prévoir) et les **tendances** dans le temps.

•**Public :** grand public éclairé, étudiants, journalistes.

Solution - Proposition

How : l'encodage
•**Marque :** le point (la bulle), une par pays.
•**Canaux :**
- position horizontale : PIB/hab. ;
- position verticale : espérance de vie ;
- aire : population ;
- teinte : continent.

•**Interactions :** curseur temporel (animation), survol, sélection de pays, bascule entre échelle log et linéaire.

Est-ce efficace ?

Points forts

•Les deux variables les plus importantes sont encodées par la **position**, le canal le plus précis : la corrélation se lit immédiatement.

•L'**échelle logarithmique** est le choix décisif. La relation suit une tendance logarithmique : chaque gain de PIB rapporte de moins en moins d'années d'espérance de vie à mesure que le pays s'enrichit. En échelle linéaire, les pays pauvres seraient écrasés contre l'axe. vizhub

•La teinte pour le continent convient à un attribut catégoriel avec peu de valeurs.

Limites

•L'**aire** est un canal peu précis : on perçoit mal les rapports de population entre bulles.

•**Chevauchement** : les grosses bulles (Chine, Inde) masquent des petits pays.

•L'échelle log est **difficile à lire** pour un public non averti, qui peut sous-estimer les écarts de richesse.

•Le graphique invite à une lecture **causale**, « la richesse fait vivre plus longtemps », alors qu'il ne montre qu'une corrélation. Certains critiques soulignent d'ailleurs que la façon de présenter ces données peut raconter une histoire trompeuse. taxresearch

•La couleur par continent cache la grande diversité *à l'intérieur* d'un même continent.

Validation d'une visualisation

CHAPITRE 4

Valider une visualisation

Objectifs : à la fin de ce chapitre, vous saurez…

- décrire les quatre niveaux imbriqués de conception ;
- associer à chaque niveau sa menace et ses méthodes de validation ;
- choisir une méthode d'évaluation adaptée à votre projet.

55

CH. 4 · VALIDATION

Quatre niveaux de conception imbriqués



- **Domaine :** qui sont les utilisateurs, leurs questions ?
- **Abstraction :** quoi montrer (What), pourquoi (Why) ?
- **Idiome :** comment montrer : encodage, interaction (How)
- **Algorithme :** comment calculer efficacement ?

À retenir Une erreur à un niveau se propage à tous les niveaux en dessous.

CH. 4 · VALIDATION

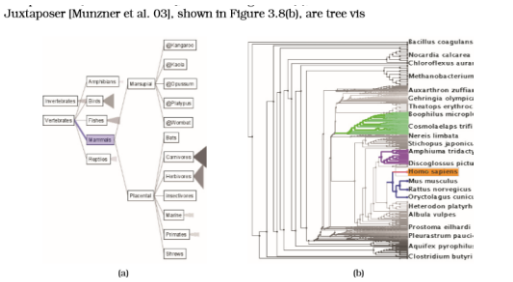
Menaces et méthodes de validation

Niveau	Menace	Valider en amont	Valider en aval
Domaine	Mauvaise compréhension des besoins	Observer, interroger les utilisateurs	Mesurer l'adoption
Abstraction	Montrer la mauvaise chose	—	Étude de terrain avec les utilisateurs cibles
Idiome	La manière de montrer ne fonctionne pas	Justifier par les principes de perception	Étude en laboratoire ; analyse des images
Algorithme	Code trop lent	Analyser la complexité	Mesurer temps et mémoire

À retenir Projet : justifiez vos idiomes, puis faites tester votre vis par quelqu'un qui ne connaît pas les données.

CH. 4 · VALIDATION

Comparer deux idiomes pour la même tâche



Comparing two idioms. (a) SpaceTree [Plaisant et al. 02]. (b) TreeJuxtaposer. From http://www.cs.umd.edu/hcil/spacetree and [Munzner et al. 03, Figure 1].

(a) SpaceTree · (b) TreeJuxtaposer

- **Même What :** un grand arbre
- **Why proche :** naviguer, localiser, comparer
- **How différent :** développer à la demande vs focus + contexte
- Le cadre permet une comparaison systématique

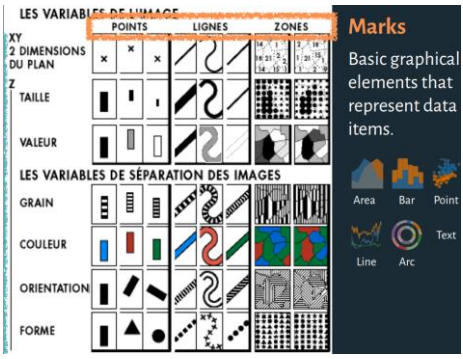
CHAPITRE 5 · HOW

Marques et canaux

Objectifs : à la fin de ce chapitre, vous saurez…

- décomposer n'importe quel graphique en marques et canaux ;
- appliquer les principes d'expressivité et d'efficacité ;
- classer les canaux selon leur précision perceptive ;
- utiliser discriminabilité, séparabilité, popout et groupement.

Héritage : la sémiologie graphique de Bertin



J. Bertin, Sémiologie graphique (1967)

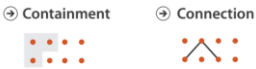
- **Implantations :** point, ligne, zone → marques
- **Variables visuelles :** position, taille, valeur, grain, couleur, orientation, forme → canaux
- Tout encodage se décompose en marques × canaux

CH. 5 · MARQUES

Les marques



Marques pour les items : point (0D), ligne (1D), zone (2D)



Marques pour les liens : inclusion et connexion

- Marque = primitive géométrique qui représente un item ou un lien
- Classée selon ses dimensions : 0D, 1D, 2D
- Les volumes (3D) sont rarement utiles
- Les inclusions peuvent être imbriquées

CH. 5 · CANAUX

Les canaux visuels

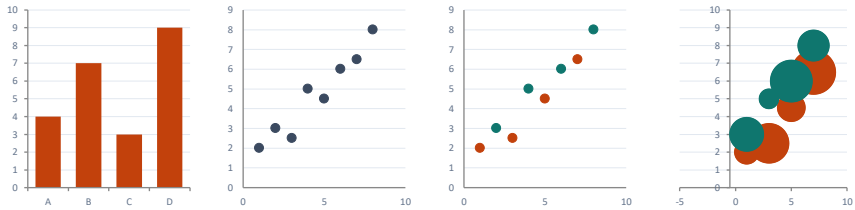


T. Munzner (2014), fig. 5.4

- Un canal contrôle l'apparence d'une marque selon la valeur d'un attribut
- **Principaux :** position, couleur, forme, inclinaison, taille
- **Autres :** courbure, texture, mouvement

CH. 5 · DÉCOMPOSER

Décomposer un graphique en marques et canaux



Barres
ligne · longueur
1 quant. + 1 cat.

Nuage de points
point · position x, y
2 quant.

+ teinte
point · x, y, teinte
+ 1 catégoriel

+ taille
point · x, y, teinte, surface
+ 1 quantitatif

À retenir Plus de canaux = plus d'information… mais tous les canaux ne se lisent pas aussi bien.

CH. 5 · CANAUX

Deux familles de canaux : identité et magnitude

◆ Canaux d'identité : quoi ? où ?

- Forme, teinte, région spatiale, mouvement
- Pas d'ordre perçu
- Pour les attributs catégoriels

▲ Canaux de magnitude : combien ?

- Position, longueur, angle, surface, luminosité, saturation
- On perçoit « plus » ou « moins »
- Pour les attributs ordonnés

À retenir Piège classique : la teinte (arc-en-ciel) n'a pas d'ordre perçu ; à éviter pour une quantité.

CH. 5 · PRINCIPES

Deux principes pour choisir : expressivité et efficacité

1 Expressivité

- Exprimer toute l'information des attributs, et rien qu'elle
- Données ordonnées → perçues comme ordonnées
- Données non ordonnées → ne pas suggérer d'ordre

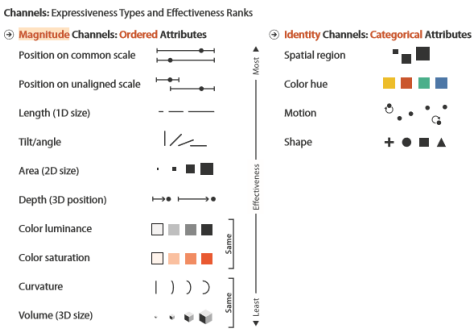
2 Efficacité

- L'attribut le plus important reçoit le canal le plus efficace
- Les attributs secondaires reçoivent des canaux moins saillants

À retenir D'abord l'expressivité (le canal est-il admissible ?), puis l'efficacité (lequel est le meilleur ?).

CH. 5 · EFFICACITÉ

Le classement des canaux

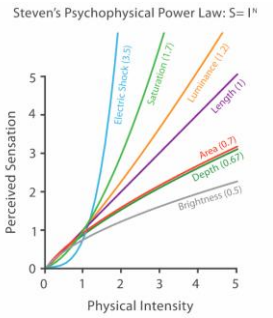


T. Munzner (2014), fig. 5.1

- **Ordonnés :** position > longueur > angle > surface > luminosité, saturation > volume
- **Catégoriels :** région spatiale > teinte > mouvement > forme
- La position est le meilleur canal pour tous les types

CH. 5 · PRÉCISION

Précision : la loi de Stevens



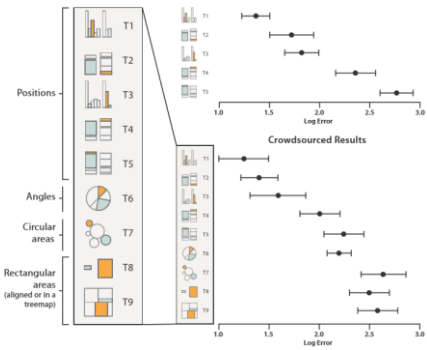
Loi de puissance de Stevens : S = I^n

Canal	Exposant n	Perception
Longueur	≈ 1	fidèle
Surface	≈ 0,7	sous-estimée
Luminosité	≈ 0,5	sous-estimée
Saturation	≈ 1,7	surestimée

À retenir Une bulle deux fois plus grande ne paraît pas deux fois plus grande.

CH. 5 · PRÉCISION

Mesurer la précision : Cleveland & McGill



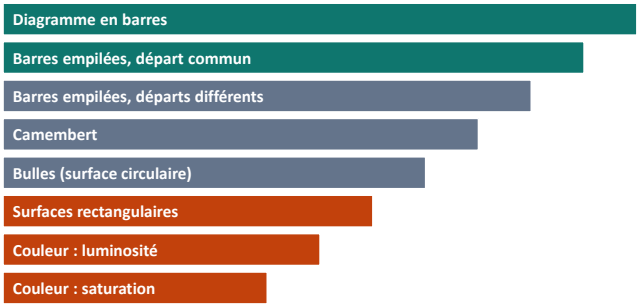
Heer & Bostock (2010), d'après Cleveland & McGill (1984)

- Position, échelle commune
- Position, échelles non alignées
- Longueur
- Angle
- Surface
- Volume, courbure, luminosité
- Teinte (pour une quantité)

Erreur croissante ↓

CH. 5 · PRÉCISION

Bonne et mauvaise quantification



Bonne quantification

↓

Mauvaise quantification

À retenir Un camembert peut montrer une part dominante ; pour comparer précisément, utilisez des barres.

CH. 5 · DISCRIMINABILITÉ

Discriminabilité : combien de valeurs distinguer ?

6 teintes : facile



12 teintes : confusion



Formes



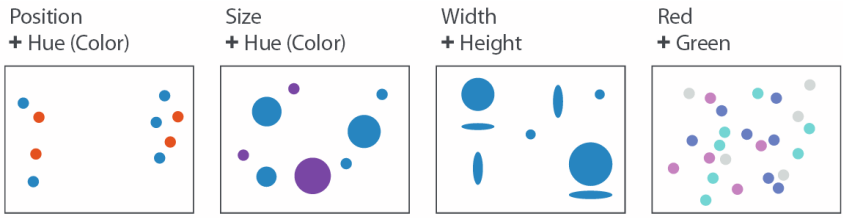
très petites : difficiles à distinguer

- Teinte catégorielle : environ 6 à 12 valeurs au maximum, moins pour de petites marques
- Trop de catégories ? Regroupez les rares en « Autres », ou utilisez la position (facettes)

À retenir Un canal a un nombre limité de valeurs distinguables : adaptez-le au nombre de catégories.

CH. 5 · SÉPARABILITÉ

Séparabilité : les canaux interfèrent

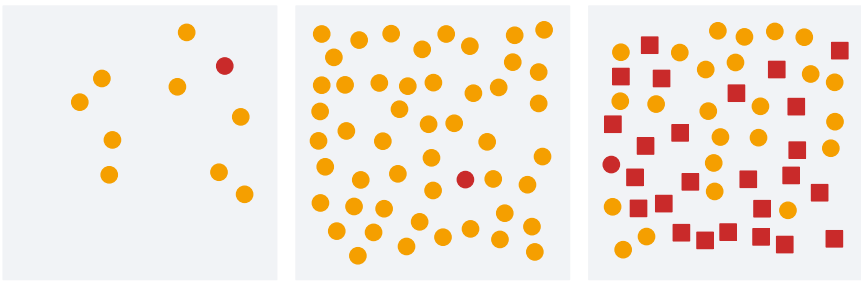


Entièrement séparables → intégraux

À retenir Trop d'attributs sur une même marque brouillent le message principal.

CH. 5 · POPOUT

Popout : trouvez le cercle rouge

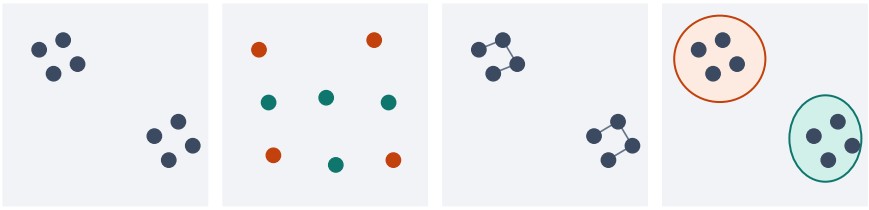


10 éléments | 50 éléments | Conjonction : couleur + forme

À retenir Un seul canal distinctif → détection immédiate. Une conjonction de canaux → recherche lente.

CH. 5 · GROUPEMENT

Groupement : inclusion, connexion, proximité, teinte



Proximité | Teinte | Connexion | Inclusion

Signal de groupement de plus en plus fort →

À retenir L'inclusion est le signal de groupement le plus fort, la connexion le deuxième.

CH. 5 · COULEUR

La couleur : un canal, trois dimensions

Teinte

« Quelle couleur ? » Canal d'identité : pour les catégories.

Saturation

Intensité de la couleur. Canal de magnitude, peu de niveaux distinguables.

Luminosité

Du sombre au clair. Canal de magnitude, le plus fiable pour les quantités.

À retenir Pas d'arc-en-ciel pour une quantité : utilisez une rampe de luminosité (ex. : viridis).

CH. 5 · RÈGLES

Règles pratiques (Munzner, ch. 6)

1 **Pas de 3D injustifiée**
occlusion, perspective, texte incliné

2 **Pas de 2D injustifiée**
un tableau trié suffit parfois

3 **Les yeux battent la mémoire**
juxtaposer plutôt que mémoriser

4 **Résolution avant immersion**
l'écran bat souvent la RV

5 **Vue d'ensemble d'abord**
puis zoom, filtre, détails

6 **Réactivité indispensable**
l'interaction doit être fluide

7 **Fonctionne en noir et blanc**
luminosité ; accessibilité

8 **La fonction avant la forme**
efficace d'abord, beau ensuite

À retenir Règles par défaut : on peut y déroger, mais avec une justification.

CH. 5 · CRITIQUER

Critiquer et valider ses propres figures

? Le test du regard neuf

- Que vous dit ce graphique ?
- Est-ce le message voulu ?
- Voit-on d'abord le point le plus important ?

Règles de rédaction

- Pas de figure inutile : un tableau serait-il meilleur ?
- Un seul message par figure
- Ne pas dépendre uniquement de la couleur
- Figures autonomes : titre, axes, unités, source

À retenir Faites tester chaque figure par quelqu'un qui ne connaît pas vos données.

CH. 5 · SYNTHÈSE

Qu'est-ce qu'une bonne visualisation ?

1 Claire

un message, articulé avec le texte

2 Concentrée

ne mélange pas plusieurs messages

3 Lisible

expressive, efficace, bien mise en forme

4 Honnête

un reflet fidèle des données

À retenir Axe tronqué, surface proportionnelle au rayon, double axe : l'honnêteté est une responsabilité.

CH. 5 · VÉRIFIER

Testez-vous

Q1 Un attribut « pays » (25 valeurs) est codé par une rampe de gris. Quel principe est violé ? Que proposez-vous ?

Q2 Vous devez comparer précisément les parts de marché de 6 entreprises. Camembert ou diagramme en barres ? Justifiez avec le classement des canaux.

Q3 Pourquoi un cercle rouge parmi des carrés rouges et des cercles orange ne « saute »-t-il pas aux yeux ?

OUVERTURE

Et après ? De la visualisation à l'analytique visuelle

Visualisation (Shneiderman, 1996)

Overview first, zoom and filter, then details-on-demand.

Analytique visuelle (Keim et al., 2008)

Analyse first, show the important, zoom, filter and analyse further, details on demand.

Analytique visuelle : « la science du raisonnement analytique facilité par des interfaces visuelles interactives » — Thomas & Cook (2005)

À retenir La partie 2 couple analyse automatique (statistiques, apprentissage) et visualisation interactive.

RÉFÉRENCES

Références

- T. Munzner (2014). Visualization Analysis and Design. CRC Press. — référence principale
- J. Bertin (1967). Sémiologie graphique. Mouton / Gauthier-Villars.
- S. Card, J. Mackinlay, B. Shneiderman (1999). Readings in Information Visualization: Using Vision to Think. Morgan Kaufmann.
- B. Shneiderman (1996). The eyes have it: a task by data type taxonomy for information visualizations. IEEE VL.
- J. Mackinlay (1986). Automating the design of graphical presentations. ACM TOG 5(2).
- W. Cleveland, R. McGill (1984). Graphical perception. JASA 79(387).
- J. Heer, M. Bostock (2010). Crowdsourcing graphical perception. ACM CHI.
- S. S. Stevens (1946). On the theory of scales of measurement. Science 103.
- F. Anscombe (1973). Graphs in statistical analysis. The American Statistician 27(1).
- J. Matejka, G. Fitzmaurice (2017). Same stats, different graphs. ACM CHI.
- T. Munzner (2009). A nested model for visualization design and validation. IEEE TVCG 15(6).
- J. Thomas, K. Cook (2005). Illuminating the Path. IEEE Press.
- D. Keim et al. (2008). Visual analytics: definition, process, and challenges. LNCS 4950.